ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC BÁCH KHOA
KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

Kho Dữ Liệu và Hệ hỗ trợ quyết định - BÀI TẬP LỚN

Xây dựng hệ thống Data Warehouse và phân tích dữ liệu bán lẻ trực tuyến

---

Giảng viên hướng dẫn: Bùi Tiến Đức
Sinh viên thực hiện: Phạm Quang Hiếu - 2310974
Nguyễn Trung Hiếu - 2310965

TP. HỒ CHÍ MINH, THÁNG 04 NĂM 2026

Mục lục

1 Introduction and Statement of Purpose **3**
1.1 Background and Motivation . . . 3
1.2 Research Problem and Objectives . . . 3
1.3 Importance and Relevance . . . 3
1.4 Dataset Context . . . 4
1.5 Brief Introduction to Data Mining Techniques . . . 4

2 Data Preprocessing **4**
2.1 Dataset Source . . . 4
2.2 General Information about the Dataset . . . 5
2.3 Data Cleaning and Preprocessing . . . 5
2.3.1 Xử lý giá trị thiếu (Missing Values) . . . 5
2.3.2 Loại bỏ bản ghi trùng lặp (Duplicates) . . . 5
2.3.3 Loại bỏ dữ liệu nhiễu (Noisy/Inconsistent Data) . . . 6
2.4 Data Transformation . . . 6
2.4.1 Chuẩn hóa dữ liệu (Normalization/Standardization) . . . 6
2.4.2 Biến đổi dữ liệu (Feature Engineering) . . . 7
2.4.3 Encoding Categorical Variables . . . 7
2.5 Data Integration . . . 7
2.6 Feature Selection . . . 7

3 System Architecture **8**
3.1 Overall Architecture . . . 8
3.2 Component Details . . . 8
3.3 Star Schema Design . . . 9

4 Data Mining Methodology **10**
4.1 K-Means Clustering . . . 10
4.1.1 Algorithm Description . . . 10
4.1.2 Training Process . . . 10
4.1.3 Evaluation Metrics . . . 10
4.2 XGBoost Regression (CLV Prediction) . . . 11
4.2.1 Algorithm Description . . . 11
4.2.2 Training Process . . . 11
4.2.3 Evaluation Metrics . . . 12
4.3 FP-Growth Association Rules . . . 12
4.3.1 Algorithm Description . . . 12
4.3.2 Training Process . . . 12

5 Experimental Results and Analysis **12**
5.1 Experimental Output Summary 12
5.2 Quantitative Model Evaluation 15
5.3 K-Means Clustering Results and Analysis 17
5.4 XGBoost CLV Prediction Results and Analysis 19
5.5 FP-Growth Association Rules Results and Analysis 21
5.6 Business Patterns and Insights from Data 22
5.7 Objective Achievement Discussion 24

6 Knowledge Presentation / Application **24**
6.1 Interactive Dashboard 24
6.2 Decision Support Applications 25
6.3 Minh họa kiểm thử và recommendation 25

7 Pipeline Logging and Reproducibility **25**
7.1 Generated Artifacts 26

8 Conclusion and Future Work **26**
8.1 Main Findings and Contributions 26
8.2 Limitations 27
8.3 Future Work 27

1 Introduction and Statement of Purpose

1.1 Background and Motivation

Trong bối cảnh thương mại điện tử phát triển mạnh mẽ, các doanh nghiệp bán lẻ trực tuyến ngày càng tạo ra lượng dữ liệu giao dịch khổng lồ. Tuy nhiên, việc khai thác hiệu quả các dữ liệu này để đưa ra quyết định kinh doanh vẫn là thách thức lớn. Các hệ thống quản lý giao dịch truyền thống (OLTP) không phù hợp cho phân tích phức tạp vì chúng được tối ưu cho xử lý giao dịch, không phải truy vấn phân tích.

Data Warehouse (DW) kết hợp với Business Intelligence (BI) và Data Mining đã chứng minh khả năng giải quyết vấn đề này bằng cách cung cấp một kiến trúc tích hợp cho việc thu thập, lưu trữ, phân tích và trực quan hóa dữ liệu.

1.2 Research Problem and Objectives

Vấn đề nghiên cứu: Làm thế nào để xây dựng một hệ thống Data Warehouse hoàn chỉnh cho dữ liệu bán lẻ trực tuyến, cho phép phân tích hành vi khách hàng và dự đoán giá trị khách hàng?

Mục tiêu cụ thể:

1. Xây dựng pipeline ETL tự động để trích xuất, làm sạch, và nạp dữ liệu vào Data Warehouse.
2. Thiết kế lược đồ hình sao (Star Schema) phù hợp cho phân tích bán lẻ.
3. Phân cụm khách hàng bằng K-Means dựa trên đặc trưng RFM (Recency, Frequency, Monetary).
4. Dự đoán giá trị vòng đời khách hàng (Customer Lifetime Value - CLV) bằng XGBoost.
5. Khám phá luật kết hợp sản phẩm bằng FP-Growth để gợi ý bán chéo.
6. Trực quan hóa kết quả qua dashboard tương tác (Streamlit + Plotly).

1.3 Importance and Relevance

Dự án giải quyết ba nhu cầu thực tiễn quan trọng:

- **Quản trị khách hàng:** Phân cụm RFM giúp doanh nghiệp xác định nhóm khách hàng giá trị cao, khách hàng có nguy cơ rời bỏ, và khách hàng mới cần nuôi dưỡng.

- **Dự báo doanh thu:** Mô hình CLV cho phép ước lượng chi tiêu tương lai, hỗ trợ lập ngân sách marketing.
- **Tối ưu bán hàng:** Luật kết hợp sản phẩm cung cấp gợi ý bán chéo (cross-selling), tăng giá trị đơn hàng trung bình.

1.4 Dataset Context

Tập dữ liệu *Online Retail* thuộc miền **thương mại điện tử (E-commerce)**, chứa các giao dịch thực tế từ một công ty bán lẻ quà tặng tại Vương quốc Anh trong giai đoạn 01/12/2010 – 09/12/2011. Dữ liệu bao gồm thông tin hóa đơn, sản phẩm, khách hàng và quốc gia.

1.5 Brief Introduction to Data Mining Techniques

Dự án sử dụng ba kỹ thuật khai phá dữ liệu chính:

- **K-Means Clustering**: Phân cụm khách hàng không giám sát dựa trên đặc trưng RFM, phát hiện các phân khúc khách hàng tự nhiên.
- **XGBoost Regression**: Mô hình gradient boosting cho bài toán hồi quy dự đoán chi tiêu tương lai (CLV), kết hợp nhiều cây quyết định yếu thành mô hình mạnh.
- **FP-Growth + Association Rules**: Khai phá tập phổ biến và luật kết hợp từ giỏ hàng, phát hiện các mẫu mua hàng đồng thời.

2 Data Preprocessing

2.1 Dataset Source

Tập dữ liệu được lấy từ **Kaggle**:

https://www.kaggle.com/datasets/ulrikthygepedersen/online-retail-dataset.

Đây là bộ dữ liệu giao dịch thực tế từ một công ty bán lẻ trực tuyến tại UK, được sử dụng rộng rãi trong nghiên cứu RFM, market basket analysis, và customer segmentation.

2.2 General Information about the Dataset

Bảng 1: Tổng quan tập dữ liệu

Thuộc tính	**Giá trị**
Số lượng bản ghi (raw)	541,909
Số lượng thuộc tính	8
Định dạng	CSV (ISO-8859-1)
Kích thước file	∼46 MB
Giai đoạn dữ liệu	01/12/2010 – 09/12/2011

Bảng 2: Chi tiết các thuộc tính

Thuộc tính	**Kiểu**	**Phân loại**	**Mô tả**
InvoiceNo	String	Categorical	Mã hóa đơn (C = cancelled)
StockCode	String	Categorical	Mã sản phẩm
Description	String	Categorical	Tên sản phẩm
Quantity	Integer	Numerical	Số lượng mua
InvoiceDate	DateTime	Time-series	Thời gian giao dịch
UnitPrice	Float	Numerical	Đơn giá (£)
CustomerID	Float	Categorical	Mã khách hàng
Country	String	Categorical	Quốc gia

2.3 Data Cleaning and Preprocessing

Quá trình làm sạch dữ liệu được thực hiện theo 5 bước tuần tự, mỗi bước loại bỏ một loại dữ liệu không phù hợp:

2.3.1 Xử lý giá trị thiếu (Missing Values)

- `CustomerID`: ∼25% bản ghi thiếu giá trị. Do CustomerID là thuộc tính then chốt cho phân tích RFM, các bản ghi thiếu được loại bỏ hoàn toàn.
- `Description`: ∼0.27% thiếu giá trị. Được giữ lại vì không ảnh hưởng đến phân tích RFM.

2.3.2 Loại bỏ bản ghi trùng lặp (Duplicates)

Phát hiện và loại bỏ các bản ghi trùng lặp hoàn toàn trong tập dữ liệu.

2.3.3 Loại bỏ dữ liệu nhiễu (Noisy/Inconsistent Data)

- **Hóa đơn bị hủy:** Các InvoiceNo bắt đầu bằng ký tự "C" biểu thị giao dịch hủy bỏ, được loại bỏ vì không phản ánh hành vi mua hàng thực tế.
- **Quantity $\leq$ 0:** Các bản ghi có số lượng âm hoặc bằng 0 được loại bỏ.
- **UnitPrice $\leq$ 0:** Các bản ghi có đơn giá âm hoặc bằng 0 được loại bỏ vì không phải giao dịch hợp lệ.

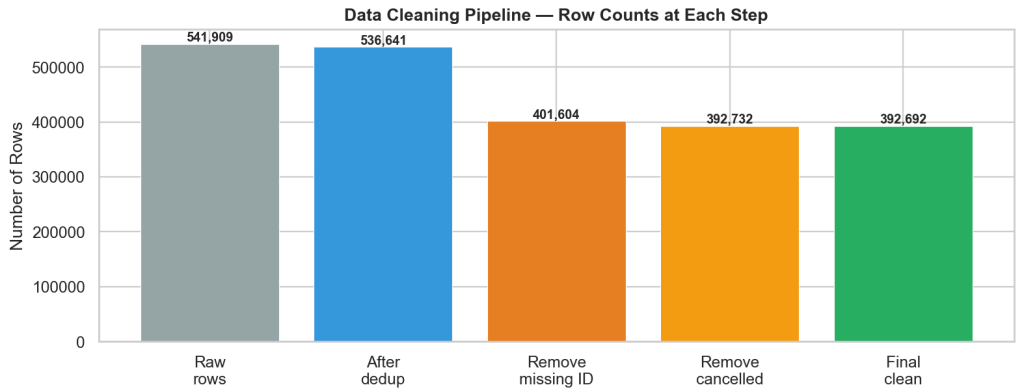

Hình 1: Tổng quan quy trình làm sạch dữ liệu: số lượng bản ghi tại mỗi bước.

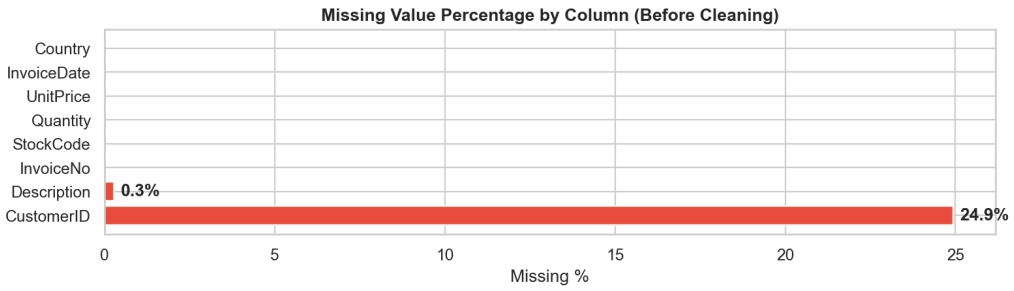

Hình 2: Tỷ lệ giá trị thiếu theo từng cột trước khi làm sạch.

2.4 Data Transformation

2.4.1 Chuẩn hóa dữ liệu (Normalization/Standardization)

Đặc trưng RFM có phân bố rất lệch (skewed), do đó nhóm áp dụng **StandardScaler** (z-score normalization) trước khi đưa vào K-Means:

$$z = \frac{x - \mu}{\sigma}$$

trong đó μ là giá trị trung bình và σ là độ lệch chuẩn của từng đặc trưng.

2.4.2 Biến đổi dữ liệu (Feature Engineering)

- **InvoiceDate:** Chuyển đổi từ chuỗi sang kiểu datetime để trích xuất Year, Month, Quarter, DayOfWeek.
- **TotalPrice:** Tạo biến mới `TotalPrice` = `Quantity` × `UnitPrice`.
- **RFM Features:**
  - *Recency* = số ngày từ lần mua cuối đến snapshot_date.
  - *Frequency* = số hóa đơn duy nhất (nunique).
  - *Monetary* = tổng chi tiêu (sum of TotalPrice).
- **CustomerID:** Chuyển từ float sang integer.

2.4.3 Encoding Categorical Variables

Đối với FP-Growth, ma trận giỏ hàng (basket matrix) sử dụng **one-hot encoding** nhị phân: mỗi sản phẩm trong mỗi hóa đơn được mã hóa thành 1 (đã mua) hoặc 0 (không mua).

2.5 Data Integration

Dự án sử dụng một tập dữ liệu duy nhất, tuy nhiên quá trình tích hợp được thực hiện khi nạp dữ liệu vào Star Schema:

- Bảng giao dịch gốc được phân tách thành 3 bảng chiều (Dim_Customer, Dim_Product, Dim_Time) và 1 bảng sự kiện (Fact_Sales).
- Bảng Customer_RFM và Customer_Cluster được tính toán và lưu riêng để phục vụ truy vấn nhanh, đồng thời hỗ trợ gắn nhãn phân khúc khách hàng trong dashboard.

2.6 Feature Selection

Đặc trưng được chọn dựa trên **phân tích RFM** — một phương pháp phân khúc khách hàng kinh điển trong marketing:

- **Recency (R):** Do mức độ gần đây của hoạt động mua hàng. Khách hàng mua gần đây có xu hướng phản hồi tốt hơn.

– **Frequency (F):** Đo mức độ thường xuyên. Khách hàng mua nhiều lần có khả năng trung thành cao.

– **Monetary (M):** Đo giá trị chi tiêu. Khách hàng chi tiêu nhiều đóng góp lớn vào doanh thu.

Ba đặc trưng này được sử dụng đồng thời cho cả K-Means (phân cụm) và XGBoost (dự đoán CLV).

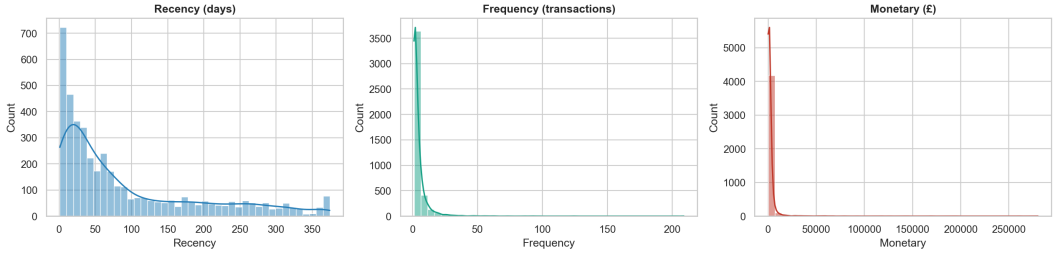

Hình 3: Phân bố của ba đặc trưng RFM: Recency, Frequency, và Monetary.

3 System Architecture

3.1 Overall Architecture

Hệ thống được thiết kế theo kiến trúc Data Source → ETL → Data Warehouse → Dashboard → AI, tuân theo mô hình Kimball:

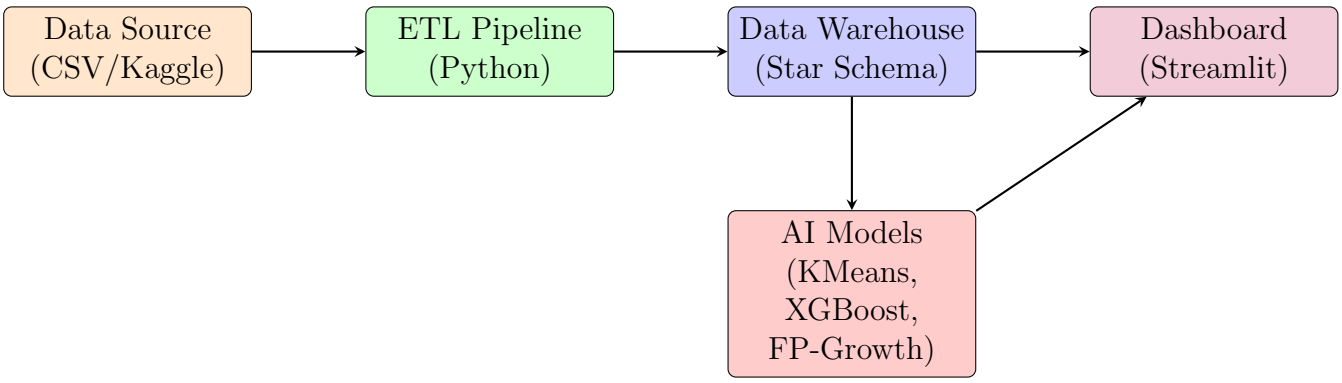

Hình 4: Kiến trúc tổng thể hệ thống.

3.2 Component Details

1. **docker-compose.yml**: Cấp phát PostgreSQL 16 với thông số chuẩn (admin/admin, retail_dw, cổng 5432). Hệ thống tự động fallback sang SQLite

khi PostgreSQL không khả dụng.

2. **etl_pipeline.py**: Pipeline chính — ETL, Star Schema loading, model training, visualization generation, và report asset creation.
3. **streamlit_app.py**: Dashboard BI tương tác và AI Customer Intelligence.
4. **requirements.txt**: Quản lý phụ thuộc Python.

3.3 Star Schema Design

Lược đồ hình sao (Star Schema) gồm 4 bảng lõi và 2 bảng phân tích bổ sung:

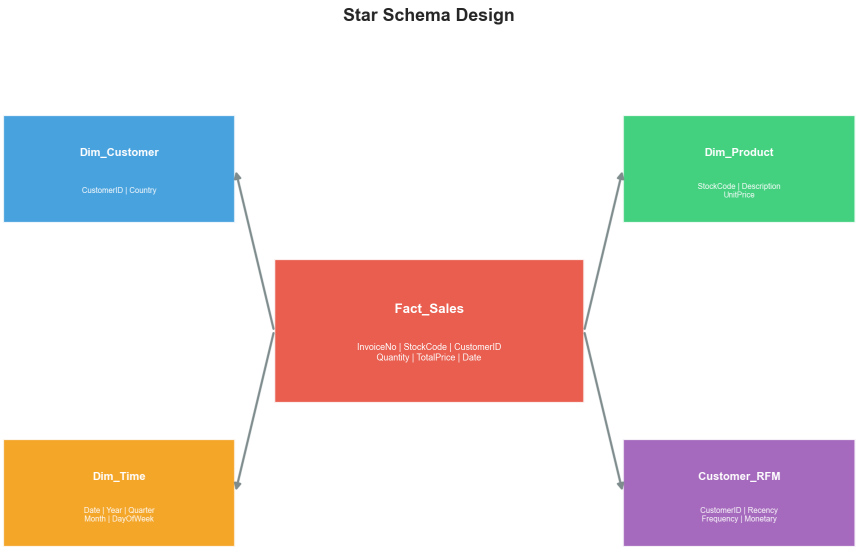

Hình 5: Thiết kế Star Schema cho Data Warehouse bán lẻ.

- `Dim_Customer(CustomerID, Country)` — Chiều khách hàng
- `Dim_Product(StockCode, Description, UnitPrice)` — Chiều sản phẩm
- `Dim_Time(Date, Year, Quarter, Month, DayOfWeek)` — Chiều thời gian
- `Fact_Sales(InvoiceNo, StockCode, CustomerID, Quantity, TotalPrice, Date)` — Bảng sự kiện

Ngoài ra, pipeline tạo thêm 2 bảng phân tích:

- `Customer_RFM(CustomerID, Recency, Frequency, Monetary)`
- `Customer_Cluster(CustomerID, Recency, Frequency, Monetary, Cluster)`

4 Data Mining Methodology

4.1 K-Means Clustering

4.1.1 Algorithm Description

K-Means là thuật toán phân cụm không giám sát, chia n điểm dữ liệu thành k cụm bằng cách tối thiểu hóa tổng bình phương khoảng cách trong cụm (inertia):

$$J = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \mu_i\|^2$$

trong đó μ_i là tâm cụm C_i.

4.1.2 Training Process

- **Dữ liệu đầu vào:** Ma trận RFM chuẩn hóa (StandardScaler) cho toàn bộ khách hàng.
- **Xác định số cụm:** Sử dụng Elbow Method kết hợp Silhouette Score cho $k \in [2, 10]$.
- **Tham số:** `n_clusters=4`, `random_state=42`, `n_init=10`.

4.1.3 Evaluation Metrics

- **Silhouette Score** $\in [-1, 1]$: Đo mức độ tương đồng trong cụm so với giữa các cụm. Giá trị càng gần 1 càng tốt.
- **Calinski-Harabasz Index:** Tỷ lệ phương sai giữa các cụm và phương sai trong cụm. Giá trị càng cao càng tốt.

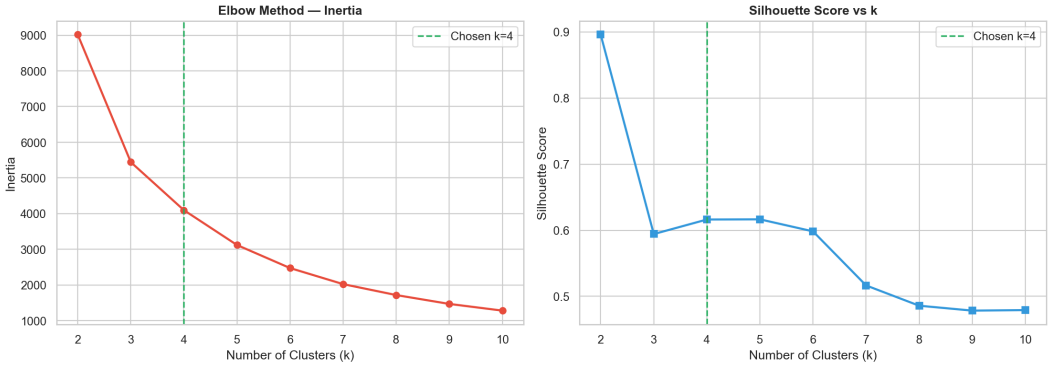

Hình 6: Elbow Method (trái) và Silhouette Score (phải) cho việc chọn số cụm tối ưu.

4.2 XGBoost Regression (CLV Prediction)

4.2.1 Algorithm Description

XGBoost (eXtreme Gradient Boosting) là thuật toán ensemble learning dạng gradient boosting, kết hợp nhiều cây quyết định yếu (weak learners) thành mô hình mạnh. Đối với bài toán hồi quy, hàm mục tiêu được tối ưu là:

$$\mathcal{L} = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k)$$

trong đó l là hàm loss (squared error) và Ω là hệ số regularization.

4.2.2 Training Process

- **Dữ liệu đầu vào:** RFM features (Recency, Frequency, Monetary) từ giai đoạn training (< split_date).
- **Biến mục tiêu:** FutureSpend — tổng chi tiêu 3 tháng cuối.
- **Train/Test split:** 80/20, random_state=42.
- **Hyperparameters:**
  - `objective = 'reg:squarederror'`
  - `n_estimators = 100`
  - `learning_rate = 0.1`
  - `max_depth = 5`

4.2.3 Evaluation Metrics

- **RMSE** (Root Mean Squared Error): $\sqrt{\frac{1}{n}\sum(y_i - \hat{y}_i)^2}$
- **MAE** (Mean Absolute Error): $\frac{1}{n}\sum|y_i - \hat{y}_i|$
- **R^2 Score**: $1 - \frac{\sum(y_i-\hat{y}_i)^2}{\sum(y_i-\bar{y})^2}$

4.3 FP-Growth Association Rules

4.3.1 Algorithm Description

FP-Growth khai phá tập phổ biến (frequent itemsets) mà không cần sinh ứng viên như Apriori, bằng cách xây dựng cây FP-Tree nén. Từ tập phổ biến, luật kết hợp được sinh ra dựa trên các ngưỡng:

- **Support:** $P(A \cup B)$ — xác suất xuất hiện đồng thời.
- **Confidence:** $P(B|A)$ — xác suất mua B khi đã mua A.
- **Lift:** $\frac{P(B|A)}{P(B)}$ — mức độ tương quan. Lift > 1 nghĩa là A và B có tương quan dương.

4.3.2 Training Process

- **Dữ liệu:** Basket matrix từ giao dịch UK (thị trường chính), one-hot encoded.
- **min_support = 0.015** (1.5% tổng giao dịch).
- **Luật:** Lọc theo `metric='lift'`, `min_threshold=1.5`.

5 Experimental Results and Analysis

5.1 Experimental Output Summary

Toàn bộ kết quả thực nghiệm được sinh tự động từ pipeline và lưu tại thư mục `report/generated`. Các bảng trong mục này phản ánh trực tiếp lần chạy gần nhất, bao gồm:

- Thống kê dữ liệu sau làm sạch và nạp kho dữ liệu;
- Chỉ số đánh giá tổng hợp cho ba mô hình KMeans, XGBoost và FP-Growth;
- Các ví dụ kiểm thử minh họa (probe/holdout/recommendation) để kiểm chứng hành vi mô hình trên dữ liệu cụ thể.

Để tăng tính dễ đọc theo phong cách bài báo nghiên cứu, các bảng được chuẩn hóa theo định dạng tối giản: tiêu đề rõ ràng, căn lề nhất quán, và ưu tiên thông tin cốt lõi thay vì liệt kê quá dài.

Bảng 3: Pipeline Data Profile

Metric	**Value**
Raw rows (incl. duplicates)	541,909
After deduplication	536,641
Duplicates removed	5,268
Rows after customer filter	401,604
Rows after cancellation filter	392,732
Final clean rows	392,692
Unique customers	4,338
Unique products	3,665
Unique invoices	18,532
Unique countries	37
Total revenue	8,887,208.89
Date range	2010-12-01 to 2011-12-09

Bảng 4: AI Model Evaluation Metrics

Metric	**Value**
KMeans Silhouette Score	0.6162
KMeans Calinski-Harabasz	3145.06
KMeans Davies-Bouldin	0.7542
XGBoost RMSE	4753.40
XGBoost MAE	764.49
XGBoost MedAE	240.13
XGBoost R^2	0.3832
XGBoost Explained Variance	0.3833
XGBoost sMAPE (%)	124.89
FP-Growth rules generated	214
FP-Growth frequent itemsets	440
FP-Growth avg support	0.0191
FP-Growth avg confidence	0.4375
FP-Growth avg lift	10.1990
FP-Growth max lift	28.6284

Bảng 5: KMeans Probe Predictions on New Customer Profiles

Profile	Recency	Frequency	Monetary	Cluster
at_risk	263.00	1.00	155.30	1
loyal	51.00	9.00	668.57	0
champion	5.00	9.00	3640.84	0

Bảng 6: XGBoost Holdout Test Examples

Recency	Frequency	Monetary	Actual	Predicted	Error
15.00	3.00	855.00	1763.23	553.38	-1209.85
24.00	3.00	539.13	213.64	313.28	99.64
15.00	5.00	797.02	219.12	553.38	334.26
91.00	2.00	1399.11	591.90	629.75	37.85
233.00	1.00	63.00	0.00	38.84	38.84

Bảng 7: Top Association Rules

Antecedents	Consequents	Support	Confidence	Lift
WOODEN HEART CHRISTMAS SCANDINAVIAN	WOODEN STAR CHRISTMAS SCANDINAVIAN	0.0180	0.6897	28.6284
WOODEN STAR CHRISTMAS SCANDINAVIAN	WOODEN HEART CHRISTMAS SCANDINAVIAN	0.0180	0.7481	28.6284
GREEN REGENCY TEACUP AND SAUCER	PINK REGENCY TEACUP AND SAUCER; ROSES REGENCY TEACUP AND SAUCER	0.0205	0.5572	24.2167
PINK REGENCY TEACUP AND SAUCER; ROSES REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER	0.0205	0.8903	24.2167
PINK REGENCY TEACUP AND SAUCER	GREEN REGENCY TEACUP AND SAUCER; ROSES REGENCY TEACUP AND SAUCER	0.0205	0.6917	24.1886

Bảng 8: Customer Recommendation Example

Field	**Value**
CustomerID	12886
Purchased items (sample)	12 PENCILS TALL TUBE WOODLAND, 3 HOOK PHOTO SHELF ANTIQUE WHITE, 3 TRADITIONAl BISCUIT CUTTERS SET, ... (+7 more)
Matched antecedents	PINK REGENCY TEACUP AND SAUCER; ROSES REGENCY TEACUP AND SAUCER
Recommended item(s)	GREEN REGENCY TEACUP AND SAUCER
Support	0.0205
Confidence	0.8903
Lift	24.2167

5.2 Quantitative Model Evaluation

Để đánh giá mức độ hoàn thành mục tiêu nghiên cứu, nhóm đối chiếu kết quả theo ba trục: *chất lượng phân cụm*, *độ chính xác dự đoán CLV*, và *mức hữu ích của luật kết hợp*.

Bên cạnh các chỉ số tổng hợp, pipeline sinh thêm các phép kiểm thử trực quan: (i) KMeans dự đoán trên 3 hồ sơ khách hàng probe, (ii) XGBoost báo cáo 5 mẫu holdout với cặp giá trị thực tế–dự đoán, và (iii) FP-Growth hiển thị top luật cùng một ví dụ recommendation cụ thể. Nhờ đó, phần đánh giá không chỉ dừng ở metric tổng quát mà còn thể hiện được khả năng ứng dụng thực tế của từng mô hình.

Bảng 9: Đánh giá định lượng theo mục tiêu mô hình

Mô hình	**Mục tiêu**	**Kết quả định lượng**	**Đánh giá**
KMeans	Phân khúc khách hàng có tính tách biệt và dễ diễn giải	Silhouette = 0.6162; Calinski-Harabasz = 3145.06; Davies-Bouldin = 0.7542	Đạt
XGBoost	Dự đoán *FutureSpend* (CLV ngắn hạn)	RMSE = 4753.40; MAE = 764.49; MedAE = 240.13; R^2 = 0.3832; Explained Variance = 0.3833; sMAPE = 124.89%	Đạt một phần
FP-Growth	Tìm luật bán chéo có ý nghĩa kinh doanh	440 frequent itemsets; 214 rules; Avg confidence = 0.4375; Avg lift = 10.1990; Max lift = 28.6284	Đạt

5.3 K-Means Clustering Results and Analysis

Hình 7: Phân bố khách hàng theo cụm (KMeans k=4).

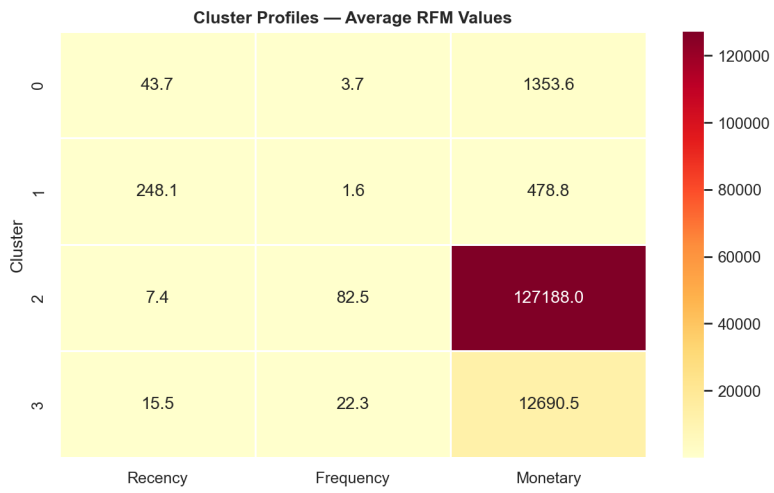

Hình 8: Heatmap giá trị RFM trung bình của mỗi cụm.

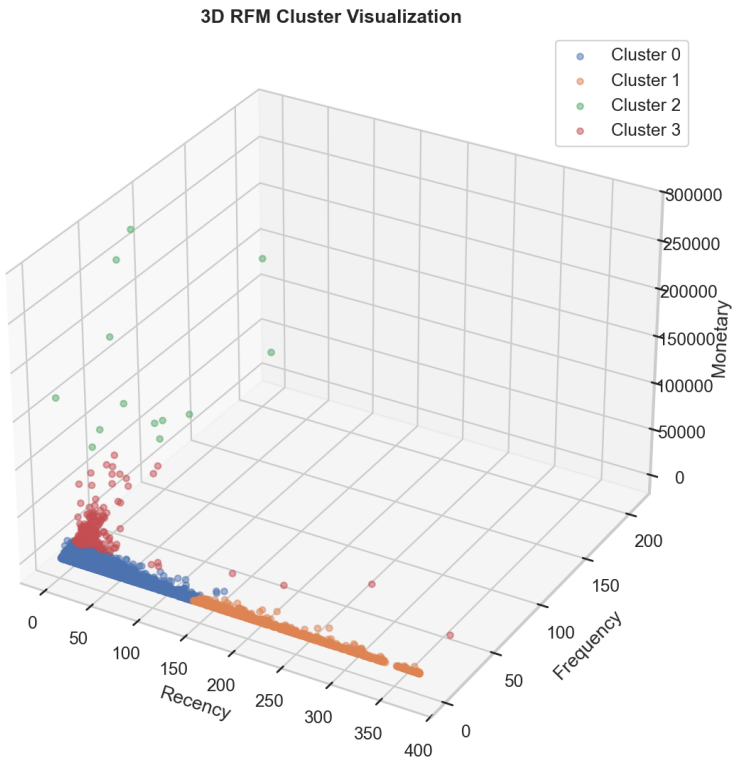

Hình 9: Trực quan hóa 3D các cụm khách hàng trong không gian RFM.

Phân tích kết quả:

- Chất lượng phân cụm ở mức tốt cho bài toán marketing (Silhouette > 0.6), các cụm tách biệt khá rõ trên không gian RFM.
- Chỉ số Davies-Bouldin nhỏ (< 1) cho thấy cụm đủ chặt và giảm chồng lấn giữa các phân khúc.
- Các probe profile mới được dùng để kiểm tra khả năng gán cụm của mô hình trước khi áp dụng trong dashboard.
- Có thể diễn giải 4 nhóm khách hàng theo hành vi:
  - **At Risk:** Recency cao, Frequency và Monetary thấp.
  - **Loyal:** Frequency ổn định, giá trị chi tiêu trung bình.
  - **Champions:** Recency thấp, Frequency và Monetary rất cao.
  - **New/Promising:** Recency thấp nhưng tần suất mua còn thấp.

5.4 XGBoost CLV Prediction Results and Analysis

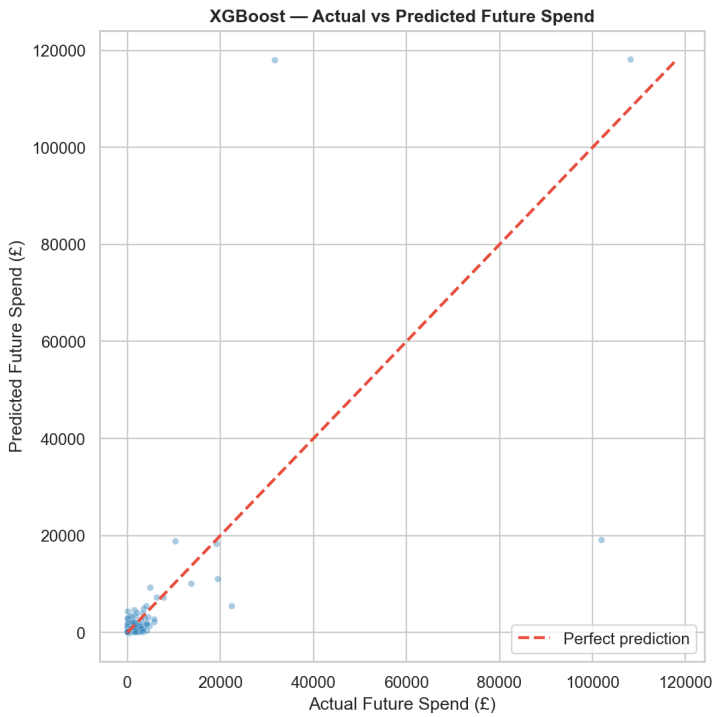

Hình 10: So sánh giá trị thực tế và dự đoán của XGBoost.

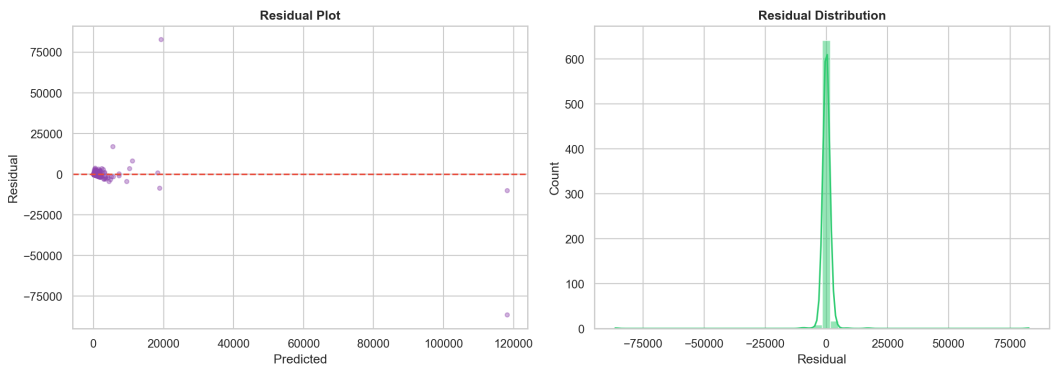

Hình 11: Phân tích phần dư (residual): scatter plot (trái) và phân bố (phải).

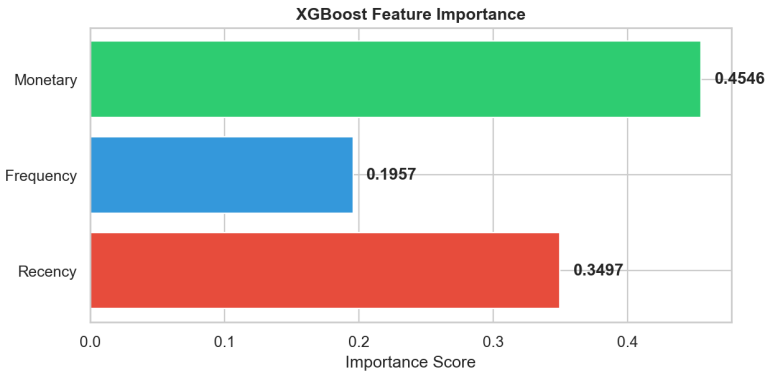

Hình 12: Mức độ quan trọng của các đặc trưng trong XGBoost.

Phân tích kết quả:

- R^2 và Explained Variance đều xấp xỉ 0.38, cho thấy mô hình giải thích được một phần đáng kể biến thiên chi tiêu tương lai.
- MAE = 764.49 và MedAE = 240.13 cho thấy sai số trung vị thấp hơn nhiều so với sai số trung bình, hàm ý có outlier chi tiêu rất lớn.
- sMAPE cao phản ánh dữ liệu CLV lệch mạnh, nhiều khách hàng có chi tiêu thấp/0 trong kỳ dự báo, làm bài toán khó hơn.
- Feature importance cho thấy **Monetary** là tín hiệu mạnh nhất, sau đó đến **Recency**; điều này phù hợp với trực giác kinh doanh.
- 5 dòng holdout test được ghi nhận để kiểm tra model trên dữ liệu chưa thấy trong quá trình huấn luyện.

5.5 FP-Growth Association Rules Results and Analysis

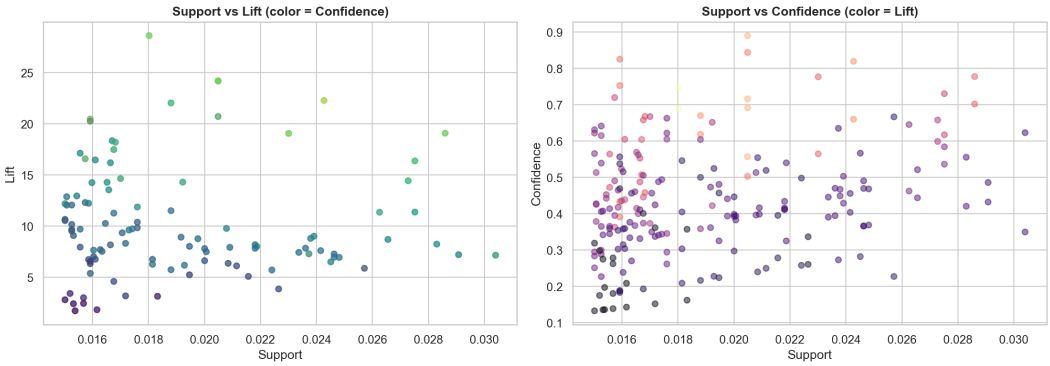

Hình 13: Support vs Lift (trái) và Support vs Confidence (phải) cho các luật kết hợp.

Phân tích kết quả:

- Số lượng luật đủ lớn (214 luật) để triển khai recommendation rule-base cho bán chéo.
- Avg lift = 10.199 và max lift = 28.628 cho thấy nhiều cặp sản phẩm có tương quan mạnh, không phải đồng xuất hiện ngẫu nhiên.
- Avg confidence = 0.4375 cho thấy khi điều kiện antecedent xảy ra, xác suất xuất hiện consequents ở mức thực dụng cho khuyến nghị.
- Pattern phổ biến là *support thấp nhưng lift cao*: phù hợp với bài toán gợi ý cá nhân hóa hơn là tối ưu hàng đại trà.
- Một ví dụ recommendation cho khách hàng cụ thể được trích từ rule phù hợp nhất để minh họa cách ứng dụng trong bán chéo.

5.6 Business Patterns and Insights from Data

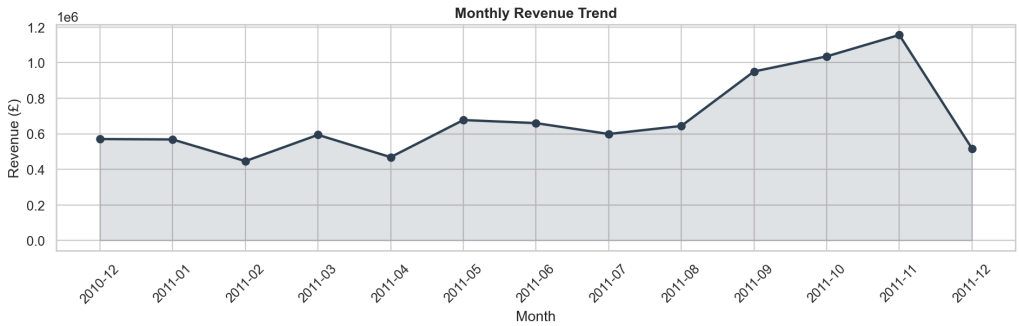

Hình 14: Xu hướng doanh thu theo tháng.

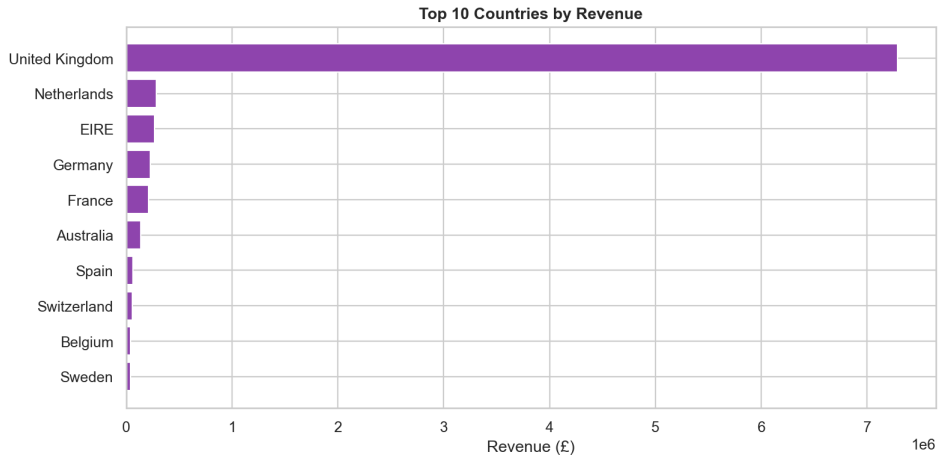

Hình 15: Top 10 quốc gia theo doanh thu.

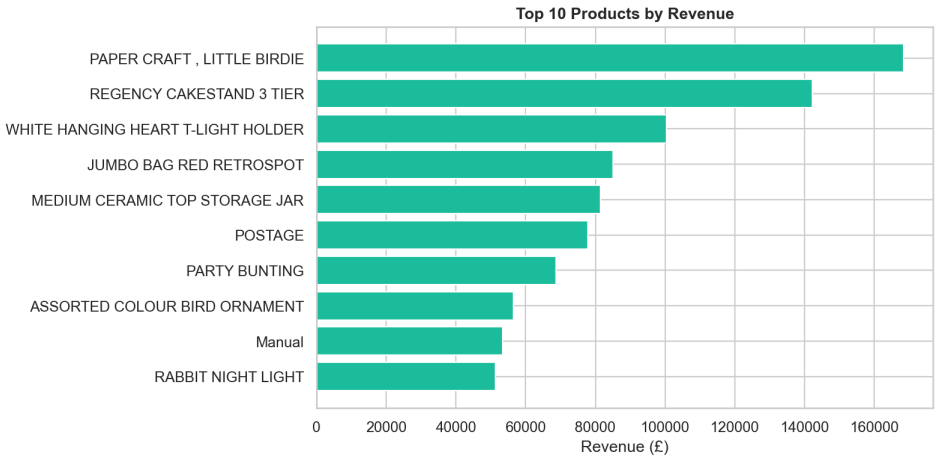

Hình 16: Top 10 sản phẩm theo doanh thu.

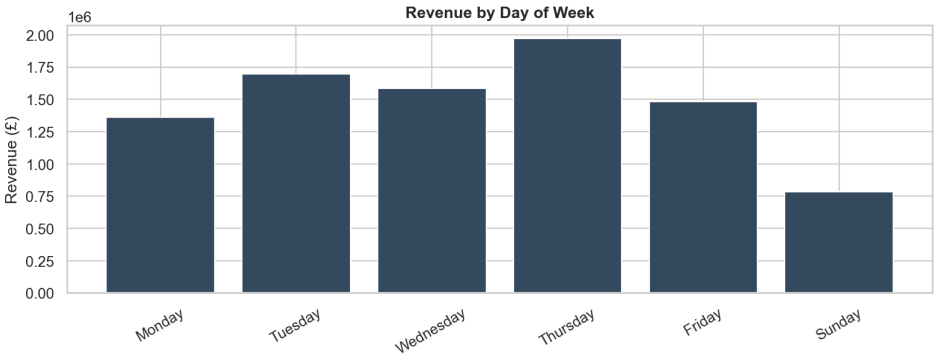

Hình 17: Doanh thu theo ngày trong tuần.

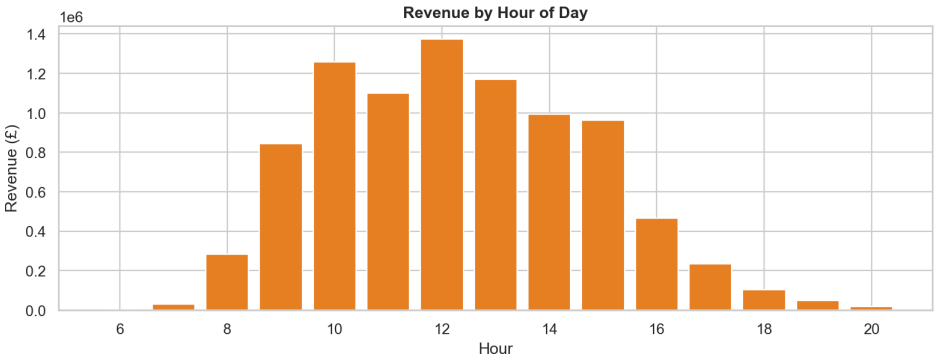

Hình 18: Doanh thu theo giờ trong ngày.

Các insight chính từ dữ liệu:

- Doanh thu có tính mùa vụ rõ, tăng mạnh vào các giai đoạn cận lễ.
- Doanh thu tập trung vào một số thị trường và nhóm sản phẩm chủ lực, gợi ý chiến lược *inventory prioritization*.
- Hành vi mua hàng theo ngày/giờ cho phép tối ưu thời điểm chạy chiến dịch marketing và đề xuất sản phẩm.
- Tồn tại nhóm khách hàng giá trị rất cao (high-value outliers) ảnh hưởng mạnh đến phân phối CLV.

5.7 Objective Achievement Discussion

Đối chiếu với mục tiêu ở Section 1, kết quả thực nghiệm cho thấy:

- **Mục tiêu phân khúc khách hàng: Đạt.** Các cụm rõ ràng và có thể gắn với chiến lược hành động cụ thể.
- **Mục tiêu dự đoán CLV: Đạt một phần.** Mô hình có năng lực dự báo nền tảng nhưng cần cải thiện cho nhóm khách hàng chi tiêu cực đoan.
- **Mục tiêu khám phá tri thức bán chéo: Đạt.** Luật kết hợp có lift cao, hữu ích cho recommendation và bundling.
- **Mục tiêu hỗ trợ ra quyết định: Đạt.** Dashboard và báo cáo tổng hợp cung cấp đủ bằng chứng định lượng và trực quan cho nghiệp vụ.

6 Knowledge Presentation / Application

6.1 Interactive Dashboard

Ứng dụng `streamlit_app.py` cung cấp 3 tab chức năng:

1. **Dashboard:** Hiển thị KPI tổng quan (Total Revenue, Total Customers, Average Spend, Average Frequency) cùng với 6+ biểu đồ tương tác Plotly (Monthly Revenue, Top Countries, Top Products, RFM Distribution, Cluster Pie Chart, Cluster Scatter).
2. **AI Customer Intelligence:** Nhập CustomerID để xem phân cụm KMeans, dự đoán CLV (XGBoost), và tối đa 5 sản phẩm gợi ý bán chéo (FP-Growth).
3. **Pipeline Log:** Xem nhật ký chi tiết của pipeline ETL + Model Training.

6.2 Decision Support Applications

Kết quả phát hiện từ dữ liệu hỗ trợ ra quyết định ở 3 cấp độ:

Bảng 10: Ứng dụng kết quả khai phá dữ liệu vào quyết định kinh doanh

Mô hình	**Tri thức phát hiện**	**Hành động kinh doanh**
KMeans Clustering	4 phân khúc khách hàng	Chiến lược marketing phân biệt: khuyến mãi cho "At Risk", loyalty program cho "Champions"
XGBoost CLV	Dự đoán chi tiêu tương lai	Phân bổ ngân sách marketing: đầu tư nhiều hơn vào khách hàng có CLV cao
FP-Growth Rules	Mẫu mua hàng đồng thời	Gợi ý bán chéo (cross-sell) trên website, email marketing, bundling sản phẩm

6.3 Minh họa kiểm thử và recommendation

Pipeline sinh thêm 3 probe profiles cho KMeans, 5 mẫu holdout cho XGBoost, và một ví dụ khách hàng cùng các sản phẩm được khuyến nghị từ luật kết hợp. Các bảng này được tạo tự động trong `generated/metrics.tex` để báo cáo luôn cập nhật đúng lần chạy gần nhất.

7 Pipeline Logging and Reproducibility

Pipeline ghi chi tiết mọi bước vào file `report/generated/pipeline.log`, bao gồm:

- Thời gian thực thi của từng phase (Extract, Transform, Load, Train, Visualize).
- Số lượng bản ghi tại mỗi bước làm sạch.
- Thống kê mô tả dữ liệu.
- Kết quả huấn luyện mô hình (Silhouette, RMSE, R^2, feature importance).
- Cluster profile (RFM trung bình mỗi cụm).
- Top 5 association rules.

Toàn bộ kết quả được lưu vào `report/generated/summary.json` dưới dạng JSON có thể tái sử dụng.

7.1 Generated Artifacts

Pipeline tạo ra các file sau:

- **Mô hình:** `output/models/kmeans.pkl`, `output/models/xgb_model.pkl`, `output/models/rules.pkl`, `output/models/scaler.pkl`
- **Báo cáo:** `report/generated/summary.json`, `metrics.tex`, `pipeline.log`
- **Hình ảnh:** 17 file PNG trong `report/generated/figures/`
- **Database:** PostgreSQL (hoặc SQLite fallback `db/retail_dw_fallback.db`)

8 Conclusion and Future Work

Phần này tổng hợp các kết quả chính của dự án, những giới hạn còn tồn tại, và các hướng mở rộng để nâng cao giá trị học thuật cũng như khả năng ứng dụng thực tiễn của hệ thống.

8.1 Main Findings and Contributions

1. **Hoàn thiện kiến trúc end-to-end cho bài toán bán lẻ:** Từ nguồn dữ liệu CSV, hệ thống thực hiện đầy đủ các bước ETL, nạp vào Data Warehouse theo Star Schema, huấn luyện mô hình AI, trực quan hóa và sinh báo cáo tự động.
2. **Đóng góp về hạ tầng dữ liệu và khả năng tái lập:** Pipeline có logging chi tiết, output chuẩn hóa (summary, metrics, figures), và cơ chế fallback PostgreSQL → SQLite, giúp chạy ổn định trong nhiều môi trường.
3. **Đóng góp về phân tích khách hàng:** KMeans xác định 4 phân khúc RFM có ý nghĩa nghiệp vụ, hỗ trợ phân biệt nhóm khách hàng giá trị cao, khách hàng trung thành, khách hàng mới và nhóm có nguy cơ rời bỏ.
4. **Đóng góp về dự báo giá trị khách hàng:** XGBoost cung cấp dự báo CLV ngắn hạn với năng lực giải thích ở mức hữu ích (R^2 dương), phù hợp làm baseline cho các chiến lược phân bổ ngân sách marketing.
5. **Đóng góp về recommendation tri thức:** FP-Growth tạo tập luật kết hợp có lift cao, cung cấp cơ sở cho cross-selling và product bundling.

6. **Đóng góp về hỗ trợ ra quyết định:** Dashboard tích hợp KPI, phân tích mô hình, và chức năng AI customer intelligence, giúp người dùng nghiệp vụ tiếp cận insight nhanh và trực quan.

Nhìn chung, hệ thống đã đạt được các mục tiêu chính đặt ra ở phần mở đầu, đặc biệt ở năng lực phân khúc khách hàng và khai phá tri thức bán chéo. Bài toán dự báo CLV đã cho kết quả khả quan nhưng vẫn còn dư địa cải thiện.

8.2 Limitations

- **Giới hạn dữ liệu và ngữ cảnh:** Tập dữ liệu chỉ bao phủ khoảng 1 năm giao dịch và thiếu biến bổ sung (nhân khẩu học, kênh marketing, hành vi web), làm giảm khả năng mô hình hóa đầy đủ vòng đời khách hàng.
- **Giới hạn của KMeans:** KMeans giả định cụm dạng cầu và nhạy với outlier; điều này có thể làm giảm chất lượng phân cụm khi dữ liệu có cấu trúc phi tuyến hoặc phân phối lệch mạnh.
- **Giới hạn của mô hình CLV:** XGBoost hiện chưa được tối ưu siêu tham số một cách hệ thống và chưa khai thác đặc trưng chuỗi thời gian sâu hơn, nên sai số vẫn cao ở nhóm khách hàng chi tiêu bất thường.
- **Giới hạn của luật kết hợp:** FP-Growth đang áp dụng cho tập UK, vì vậy tính khái quát cho các thị trường khác cần được kiểm định thêm.
- **Giới hạn triển khai hệ thống:** Dashboard hiện thiên về phân tích nội bộ, chưa có lớp bảo mật (authentication/authorization), chưa có CI/CD và chưa triển khai cloud production.

8.3 Future Work

1. **Mở rộng dữ liệu đầu vào:** Tích hợp thêm dữ liệu hành vi số (clickstream), chiến dịch marketing, đánh giá sản phẩm và dữ liệu CRM để tăng sức mạnh dự báo.
2. **Nâng cấp mô hình CLV:** Thực hiện hyperparameter tuning (Grid/Bayesian search), thử nghiệm các mô hình temporal (LSTM/Transformer), và đánh giá bằng cross-validation theo thời gian.
3. **Nâng cấp phân cụm khách hàng:** So sánh KMeans với DBSCAN, Gaussian Mixture, Hierarchical Clustering để chọn mô hình phù hợp hơn với phân phối dữ liệu thực tế.

4. **Nâng cấp recommendation:** Kết hợp luật kết hợp với phương pháp học máy (hybrid recommender), đánh giá online/offline bằng A/B testing và business KPIs.

5. **Nâng cấp hạ tầng triển khai:** Đưa pipeline lên cloud, lập lịch bằng Airflow, bổ sung CI/CD, monitoring và kiểm soát chất lượng dữ liệu tự động.

6. **Nâng cấp ứng dụng BI:** Bổ sung authentication, role-based access, và khả năng drill-down để phục vụ nhiều nhóm người dùng nghiệp vụ.