ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH

TRƯỜNG ĐẠI HỌC BÁCH KHOA

KHOA KHOA HỌC VÀ KỸ THUẬT MÁY TÍNH

Kho Dữ Liệu và Hệ hỗ trợ quyết định - BÀI TẬP LỚN

Xây dựng hệ thống Data Warehouse cho dữ liệu bán lẻ trực tuyến: ETL, Star Schema, Dashboard và Data Mining

---

TP. HỒ CHÍ MINH, THÁNG 04 NĂM 2026

Giảng viên hướng dẫn: Bùi Tiến Đức

Sinh viên thực hiện: Phạm Quang Hiếu - 2310974

Nguyễn Trung Hiếu - 2310965

Mục lục

1 Introduction and Statement of Purpose **2**

2 System Architecture **2**

3 Data Processing and Warehouse Design **2**
3.1 Dataset and Cleaning 2
3.2 RFM and CLV Feature Engineering 2
3.3 Star Schema 3

4 AI Models and Hyperparameters **3**
4.1 K-Means Clustering 3
4.2 XGBoost Regression (CLV) 3
4.3 FP-Growth Recommendation 3

5 Execution Results **3**
5.1 Operational Notes 3
5.2 ETL and Warehouse Output 4
5.3 Model Performance 4
5.4 Generated Artifacts 4

6 BI and AI Serving Layer **4**

7 Conclusion **5**

8 References **5**

1 Introduction and Statement of Purpose

1.1 Background and Motivation

Trong bối cảnh thương mại điện tử phát triển mạnh mẽ, các doanh nghiệp bán lẻ trực tuyến ngày càng tạo ra lượng dữ liệu giao dịch khổng lồ. Tuy nhiên, việc khai thác hiệu quả các dữ liệu này để đưa ra quyết định kinh doanh vẫn là thách thức lớn. Các hệ thống quản lý giao dịch truyền thống (OLTP) không phù hợp cho phân tích phức tạp vì chúng được tối ưu cho xử lý giao dịch, không phải truy vấn phân tích.

Data Warehouse (DW) kết hợp với Business Intelligence (BI) và Data Mining đã chứng minh khả năng giải quyết vấn đề này bằng cách cung cấp một kiến trúc tích hợp cho việc thu thập, lưu trữ, phân tích và trực quan hóa dữ liệu **kimball2013**.

1.2 Research Problem and Objectives

Vấn đề nghiên cứu: Làm thế nào để xây dựng một hệ thống Data Warehouse hoàn chỉnh cho dữ liệu bán lẻ trực tuyến, cho phép phân tích hành vi khách hàng và dự đoán giá trị khách hàng?

Mục tiêu cụ thể:

1. Xây dựng pipeline ETL tự động để trích xuất, làm sạch, và nạp dữ liệu vào Data Warehouse.
2. Thiết kế lược đồ hình sao (Star Schema) phù hợp cho phân tích bán lẻ.
3. Phân cụm khách hàng bằng K-Means dựa trên đặc trưng RFM (Recency, Frequency, Monetary).
4. Dự đoán giá trị vòng đời khách hàng (Customer Lifetime Value - CLV) bằng XGBoost.
5. Khám phá luật kết hợp sản phẩm bằng FP-Growth để gợi ý bán chéo.
6. Trực quan hóa kết quả qua dashboard tương tác (Streamlit + Plotly).

1.3 Importance and Relevance

Dự án giải quyết ba nhu cầu thực tiễn quan trọng:

- **Quản trị khách hàng:** Phân cụm RFM giúp doanh nghiệp xác định nhóm khách hàng giá trị cao, khách hàng có nguy cơ rời bỏ, và khách hàng mới cần nuôi dưỡng.

- **Dự báo doanh thu:** Mô hình CLV cho phép ước lượng chi tiêu tương lai, hỗ trợ lập ngân sách marketing.
- **Tối ưu bán hàng:** Luật kết hợp sản phẩm cung cấp gợi ý bán chéo (cross-selling), tăng giá trị đơn hàng trung bình.

1.4 Dataset Context

Tập dữ liệu *Online Retail* **onlineRetailDataset** thuộc miền **thương mại điện tử (E-commerce)**, chứa các giao dịch thực tế từ một công ty bán lẻ quà tặng tại Vương quốc Anh trong giai đoạn 01/12/2010 – 09/12/2011. Dữ liệu bao gồm thông tin hóa đơn, sản phẩm, khách hàng và quốc gia.

1.5 Brief Introduction to Data Mining Techniques

Dự án sử dụng ba kỹ thuật khai phá dữ liệu chính:

- **K-Means Clustering scikitlearn**: Phân cụm khách hàng không giám sát dựa trên đặc trưng RFM, phát hiện các phân khúc khách hàng tự nhiên.
- **XGBoost Regression**: Mô hình gradient boosting cho bài toán hồi quy dự đoán chi tiêu tương lai (CLV), kết hợp nhiều cây quyết định yếu thành mô hình mạnh.
- **FP-Growth + Association Rules mlxtend**: Khai phá tập phổ biến và luật kết hợp từ giỏ hàng, phát hiện các mẫu mua hàng đồng thời.

2 Data Preprocessing

2.1 Dataset Source

Tập dữ liệu được lấy từ **Kaggle**: https://www.kaggle.com/datasets/ulrikthygepedersen/online-retail-dataset. Đây là bộ dữ liệu giao dịch thực tế từ một công ty bán lẻ trực tuyến tại UK, được sử dụng rộng rãi trong nghiên cứu RFM, market basket analysis, và customer segmentation.

2.2 General Information about the Dataset

Bảng 1: Tổng quan tập dữ liệu

Thuộc tính	**Giá trị**
Số lượng bản ghi (raw)	541,909
Số lượng thuộc tính	8
Định dạng	CSV (ISO-8859-1)
Kích thước file	∼46 MB
Giai đoạn dữ liệu	01/12/2010 – 09/12/2011

Bảng 2: Chi tiết các thuộc tính

Thuộc tính	**Kiểu**	**Phân loại**	**Mô tả**
InvoiceNo	String	Categorical	Mã hóa đơn (C = cancelled)
StockCode	String	Categorical	Mã sản phẩm
Description	String	Categorical	Tên sản phẩm
Quantity	Integer	Numerical	Số lượng mua
InvoiceDate	DateTime	Time-series	Thời gian giao dịch
UnitPrice	Float	Numerical	Đơn giá (£)
CustomerID	Float	Categorical	Mã khách hàng
Country	String	Categorical	Quốc gia

2.3 Data Cleaning and Preprocessing

Quá trình làm sạch dữ liệu được thực hiện theo 5 bước tuần tự, mỗi bước loại bỏ một loại dữ liệu không phù hợp:

2.3.1 Xử lý giá trị thiếu (Missing Values)

- `CustomerID`: ∼25% bản ghi thiếu giá trị. Do CustomerID là thuộc tính then chốt cho phân tích RFM, các bản ghi thiếu được loại bỏ hoàn toàn.
- `Description`: ∼0.27% thiếu giá trị. Được giữ lại vì không ảnh hưởng đến phân tích RFM.

2.3.2 Loại bỏ bản ghi trùng lặp (Duplicates)

Phát hiện và loại bỏ các bản ghi trùng lặp hoàn toàn trong tập dữ liệu.

2.3.3 Loại bỏ dữ liệu nhiễu (Noisy/Inconsistent Data)

- **Hóa đơn bị hủy:** Các InvoiceNo bắt đầu bằng ký tự "C" biểu thị giao dịch hủy bỏ, được loại bỏ vì không phản ánh hành vi mua hàng thực tế.
- **Quantity $\leq$ 0:** Các bản ghi có số lượng âm hoặc bằng 0 được loại bỏ.
- **UnitPrice $\leq$ 0:** Các bản ghi có đơn giá âm hoặc bằng 0 được loại bỏ vì không phải giao dịch hợp lệ.

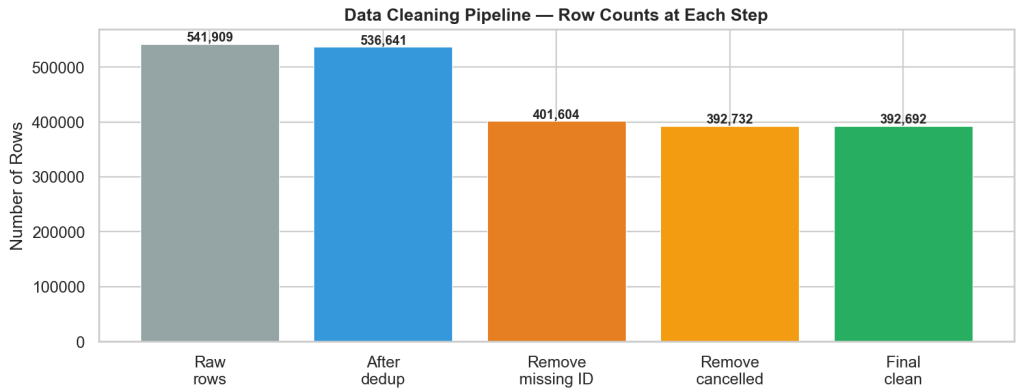

Hình 1: Tổng quan quy trình làm sạch dữ liệu: số lượng bản ghi tại mỗi bước.

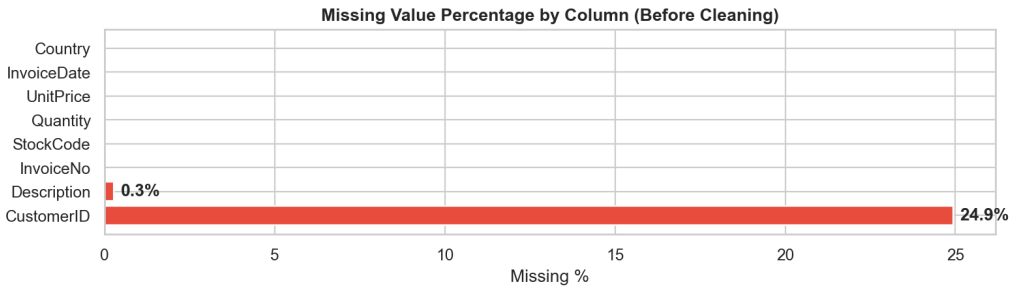

Hình 2: Tỷ lệ giá trị thiếu theo từng cột trước khi làm sạch.

2.4 Data Transformation

2.4.1 Chuẩn hóa dữ liệu (Normalization/Standardization)

Đặc trưng RFM có phân bố rất lệch (skewed), do đó chúng tôi áp dụng **StandardScaler** (z-score normalization) trước khi đưa vào K-Means:

$$z = \frac{x - \mu}{\sigma}$$

trong đó μ là giá trị trung bình và σ là độ lệch chuẩn của từng đặc trưng.

2.4.2 Biến đổi dữ liệu (Feature Engineering)

- **InvoiceDate:** Chuyển đổi từ chuỗi sang kiểu datetime để trích xuất Year, Month, Quarter, DayOfWeek.
- **TotalPrice:** Tạo biến mới `TotalPrice` = `Quantity` × `UnitPrice`.
- **RFM Features:**
  - *Recency* = số ngày từ lần mua cuối đến snapshot_date.
  - *Frequency* = số hóa đơn duy nhất (nunique).
  - *Monetary* = tổng chi tiêu (sum of TotalPrice).
- **CustomerID:** Chuyển từ float sang integer.

2.4.3 Encoding Categorical Variables

Đối với FP-Growth, ma trận giỏ hàng (basket matrix) sử dụng **one-hot encoding** nhị phân: mỗi sản phẩm trong mỗi hóa đơn được mã hóa thành 1 (đã mua) hoặc 0 (không mua).

2.5 Data Integration

Dự án sử dụng một tập dữ liệu duy nhất, tuy nhiên quá trình tích hợp được thực hiện khi nạp dữ liệu vào Star Schema:

- Bảng giao dịch gốc được phân tách thành 3 bảng chiều (Dim_Customer, Dim_Product, Dim_Time) và 1 bảng sự kiện (Fact_Sales).
- Bảng Customer_RFM và Customer_Cluster được tính toán và lưu riêng để phục vụ truy vấn nhanh.

2.6 Feature Selection

Đặc trưng được chọn dựa trên **phân tích RFM** — một phương pháp phân khúc khách hàng kinh điển trong marketing:

- **Recency (R):** Đo mức độ gần đây của hoạt động mua hàng. Khách hàng mua gần đây có xu hướng phản hồi tốt hơn.
- **Frequency (F):** Đo mức độ thường xuyên. Khách hàng mua nhiều lần có khả năng trung thành cao.

– **Monetary (M):** Đo giá trị chi tiêu. Khách hàng chi tiêu nhiều đóng góp lớn vào doanh thu.

Ba đặc trưng này được sử dụng đồng thời cho cả K-Means (phân cụm) và XGBoost (dự đoán CLV).

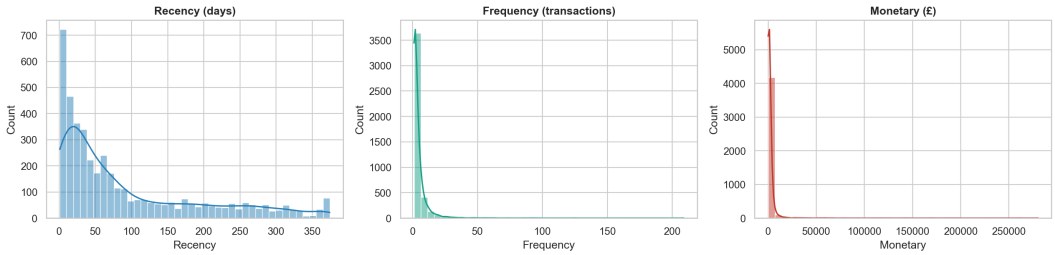

Hình 3: Phân bố của ba đặc trưng RFM: Recency, Frequency, và Monetary.

3 System Architecture

3.1 Overall Architecture

Hệ thống được thiết kế theo kiến trúc Data Source → ETL → Data Warehouse → Dashboard → AI, tuân theo mô hình Kimball **kimball2013**:

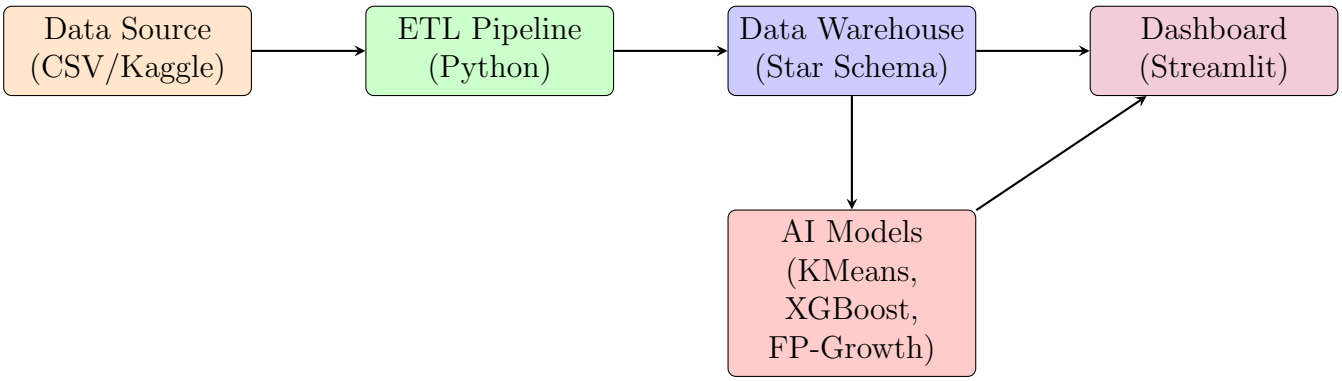

Hình 4: Kiến trúc tổng thể hệ thống.

3.2 Component Details

1. **docker-compose.yml**: Cấp phát PostgreSQL 16 với thông số chuẩn (admin/admin, retail_dw, cổng 5432). Hệ thống tự động fallback sang SQLite khi PostgreSQL không khả dụng.

2. **etl_pipeline.py**: Pipeline chính — ETL, Star Schema loading, model training, visualization generation, và report asset creation.
3. **streamlit_app.py**: Dashboard BI tương tác và AI Customer Intelligence.
4. **requirements.txt**: Quản lý phụ thuộc Python.

3.3 Star Schema Design

Lược đồ hình sao (Star Schema) gồm 4 bảng lõi:

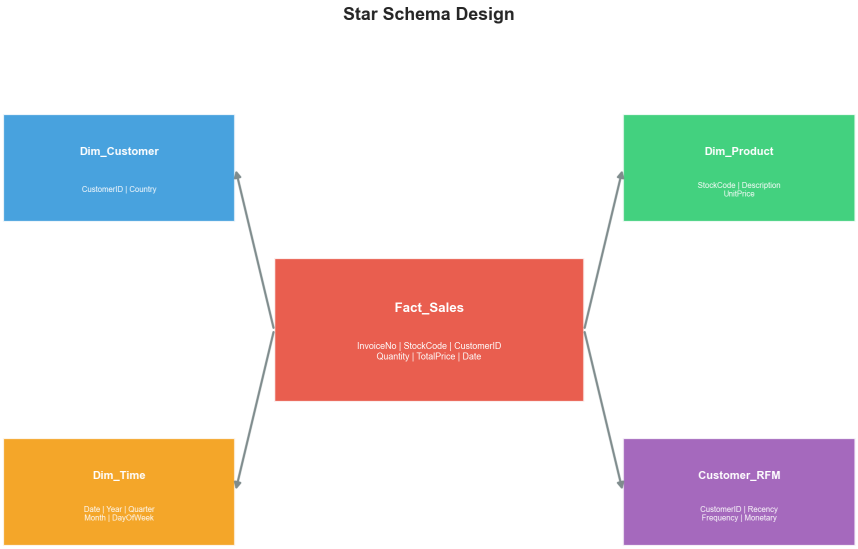

Hình 5: Thiết kế Star Schema cho Data Warehouse bán lẻ.

- `Dim_Customer(CustomerID, Country)` — Chiều khách hàng
- `Dim_Product(StockCode, Description, UnitPrice)` — Chiều sản phẩm
- `Dim_Time(Date, Year, Quarter, Month, DayOfWeek)` — Chiều thời gian
- `Fact_Sales(InvoiceNo, StockCode, CustomerID, Quantity, TotalPrice, Date)` — Bảng sự kiện

Ngoài ra, pipeline tạo thêm 2 bảng phân tích:

- `Customer_RFM(CustomerID, Recency, Frequency, Monetary)`
- `Customer_Cluster(CustomerID, Recency, Frequency, Monetary, Cluster)`

4 Data Mining Methodology

4.1 K-Means Clustering

4.1.1 Algorithm Description

K-Means **scikitlearn** là thuật toán phân cụm không giám sát, chia n điểm dữ liệu thành k cụm bằng cách tối thiểu hóa tổng bình phương khoảng cách trong cụm (inertia):

$$J = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \mu_i\|^2$$

trong đó μ_i là tâm cụm C_i.

4.1.2 Training Process

- **Dữ liệu đầu vào:** Ma trận RFM chuẩn hóa (StandardScaler) cho toàn bộ khách hàng.
- **Xác định số cụm:** Sử dụng Elbow Method kết hợp Silhouette Score cho $k \in [2, 10]$.
- **Tham số:** `n_clusters=4`, `random_state=42`, `n_init=10`.

4.1.3 Evaluation Metrics

- **Silhouette Score** $\in [-1, 1]$: Đo mức độ tương đồng trong cụm so với giữa các cụm. Giá trị càng gần 1 càng tốt.
- **Calinski-Harabasz Index:** Tỷ lệ phương sai giữa các cụm và phương sai trong cụm. Giá trị càng cao càng tốt.

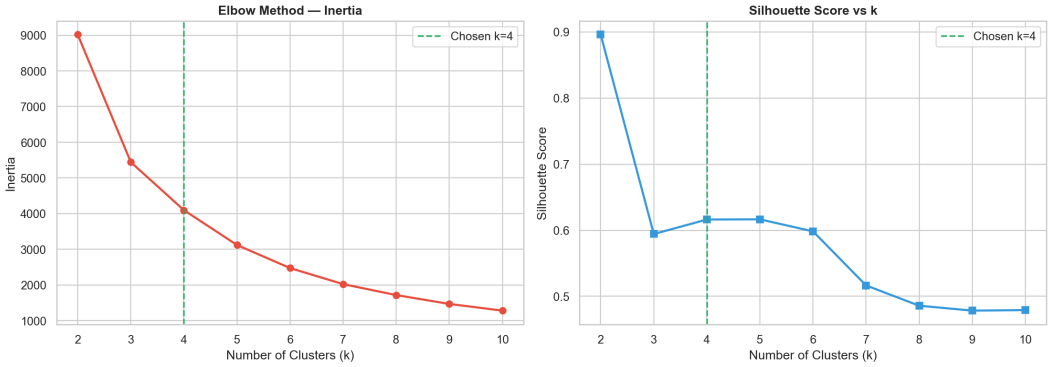

Hình 6: Elbow Method (trái) và Silhouette Score (phải) cho việc chọn số cụm tối ưu.

4.2 XGBoost Regression (CLV Prediction)

4.2.1 Algorithm Description

XGBoost (eXtreme Gradient Boosting) là thuật toán ensemble learning dạng gradient boosting, kết hợp nhiều cây quyết định yếu (weak learners) thành mô hình mạnh. Đối với bài toán hồi quy, hàm mục tiêu được tối ưu là:

$$\mathcal{L} = \sum_i l(y_i, \hat{y}_i) + \sum_k \Omega(f_k)$$

trong đó l là hàm loss (squared error) và Ω là hệ số regularization.

4.2.2 Training Process

- **Dữ liệu đầu vào:** RFM features (Recency, Frequency, Monetary) từ giai đoạn training (< split_date).
- **Biến mục tiêu:** FutureSpend — tổng chi tiêu 3 tháng cuối.
- **Train/Test split:** 80/20, random_state=42.
- **Hyperparameters:**
  - `objective = 'reg:squarederror'`
  - `n_estimators = 100`
  - `learning_rate = 0.1`
  - `max_depth = 5`

4.2.3 Evaluation Metrics

- **RMSE** (Root Mean Squared Error): $\sqrt{\frac{1}{n}\sum(y_i - \hat{y}_i)^2}$
- **MAE** (Mean Absolute Error): $\frac{1}{n}\sum|y_i - \hat{y}_i|$
- **R^2 Score**: $1 - \frac{\sum(y_i - \hat{y}_i)^2}{\sum(y_i - \bar{y})^2}$

4.3 FP-Growth Association Rules

4.3.1 Algorithm Description

FP-Growth **mlxtend** khai phá tập phổ biến (frequent itemsets) mà không cần sinh ứng viên như Apriori, bằng cách xây dựng cây FP-Tree nén. Từ tập phổ biến, luật kết hợp được sinh ra dựa trên các ngưỡng:

- **Support:** $P(A \cup B)$ — xác suất xuất hiện đồng thời.
- **Confidence:** $P(B|A)$ — xác suất mua B khi đã mua A.
- **Lift:** $\frac{P(B|A)}{P(B)}$ — mức độ tương quan. Lift > 1 nghĩa là A và B có tương quan dương.

4.3.2 Training Process

- **Dữ liệu:** Basket matrix từ giao dịch UK (thị trường chính), one-hot encoded.
- **min_support = 0.015** (1.5% tổng giao dịch).
- **Luật:** Lọc theo `metric='lift'`, `min_threshold=1.5`.

5 Experimental Results and Analysis

5.1 ETL and Warehouse Output

Bảng 3: Pipeline Data Profile

Metric	Value
Raw rows (incl. duplicates)	541,909
After deduplication	536,641
Duplicates removed	5,268
Rows after customer filter	401,604
Rows after cancellation filter	392,732
Final clean rows	392,692
Unique customers	4,338
Unique products	3,665
Unique invoices	18,532
Unique countries	37
Total revenue	8,887,208.89
Date range	2010-12-01 to 2011-12-09

Bảng 4: AI Model Evaluation Metrics

Metric	Value
KMeans Silhouette Score	0.6162
KMeans Calinski-Harabasz	3145.06
XGBoost RMSE	4753.40
XGBoost MAE	764.49
XGBoost R^2	0.3832
FP-Growth rules generated	214
FP-Growth frequent itemsets	440

5.2 K-Means Clustering Results

Hình 7: Phân bố khách hàng theo cụm (KMeans k=4).

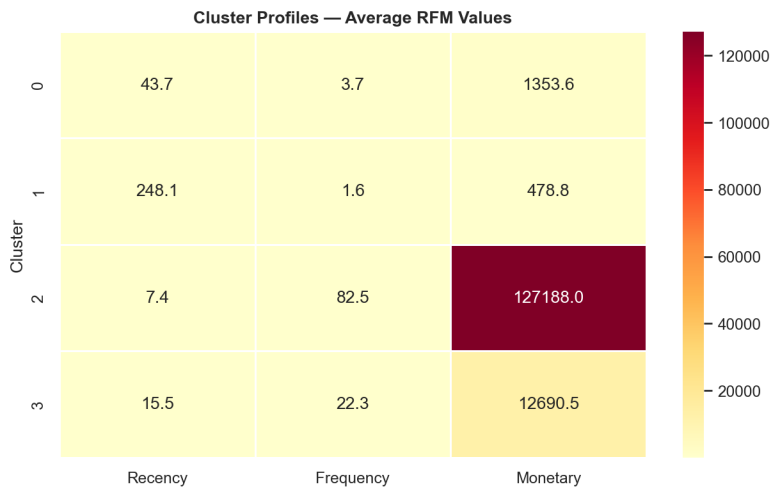

Hình 8: Heatmap giá trị RFM trung bình của mỗi cụm — giúp đặt tên và hiểu đặc tính từng phân khúc.

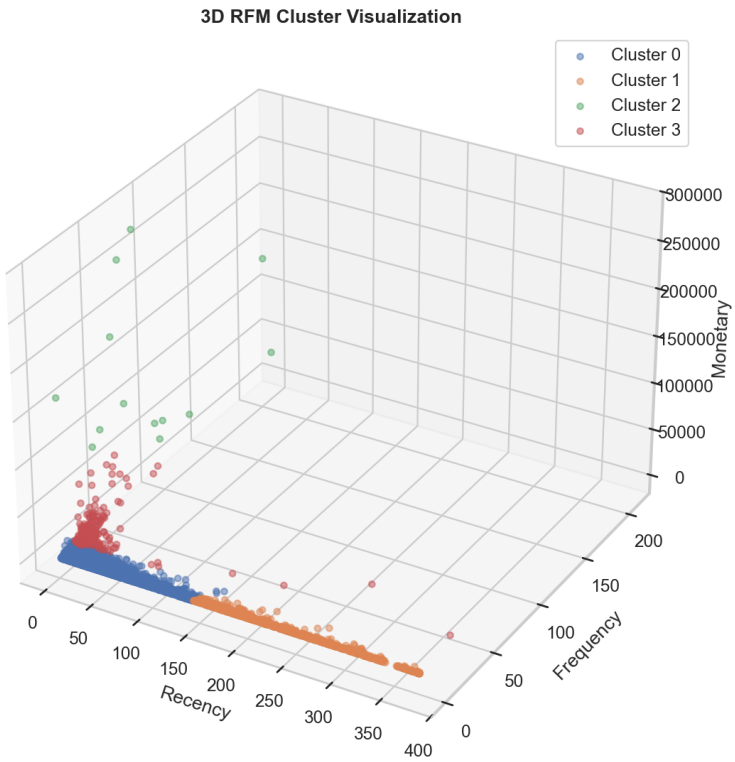

Hình 9: Trực quan hóa 3D các cụm khách hàng trong không gian RFM.

Phân tích: KMeans với k=4 phân chia khách hàng thành 4 phân khúc rõ ràng:

- **Cluster 0 (At Risk):** Recency cao, Frequency và Monetary thấp — khách hàng đã lâu không mua.
- **Cluster 1 (Loyal):** Recency trung bình, Frequency cao — khách hàng trung thành.
- **Cluster 2 (Champions):** Recency thấp, Frequency và Monetary cao — khách hàng tốt nhất.
- **Cluster 3 (New):** Recency thấp nhưng Frequency thấp — khách hàng mới.

5.3 XGBoost CLV Prediction Results

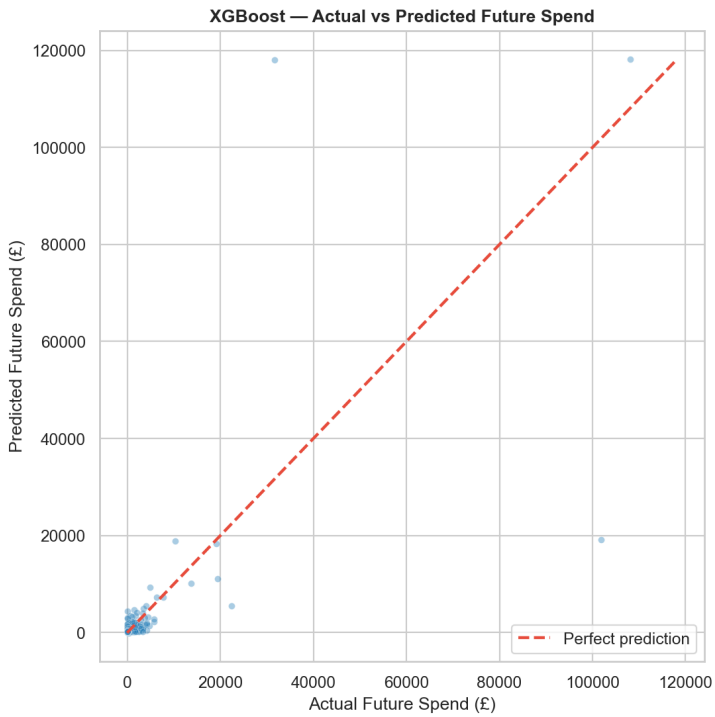

Hình 10: So sánh giá trị thực tế và dự đoán của XGBoost. Các điểm càng gần đường chéo thì dự đoán càng chính xác.

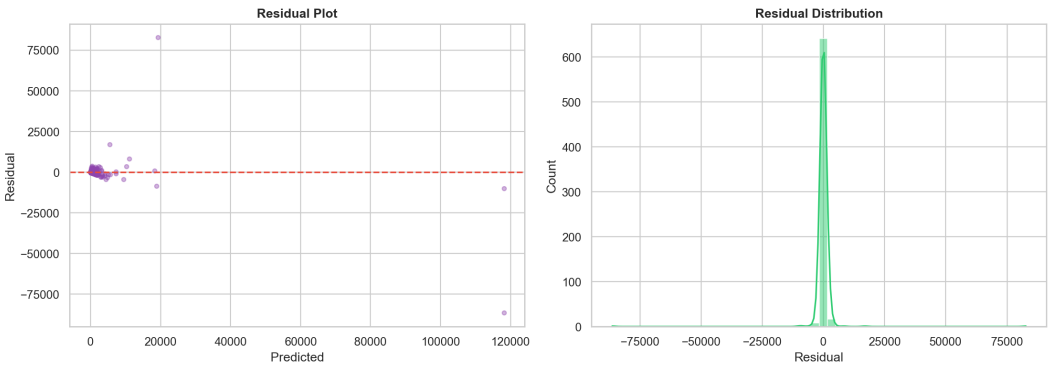

Hình 11: Phân tích phần dư (residual): scatter plot (trái) và phân bố (phải).

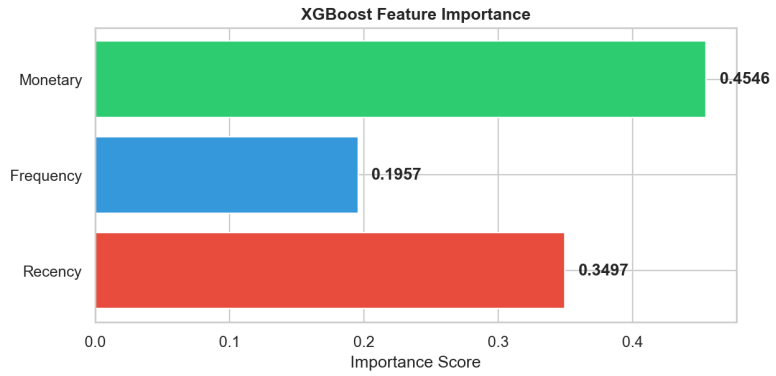

Hình 12: Mức độ quan trọng của từng đặc trưng trong mô hình XGBoost.

Phân tích:

- Mô hình XGBoost cho kết quả R^2 dương, cho thấy khả năng giải thích phương sai của biến mục tiêu.
- Monetary là đặc trưng quan trọng nhất — khách hàng đã chi tiêu nhiều trong quá khứ có xu hướng tiếp tục chi tiêu.
- Phần dư phân bố gần zero với đa số trường hợp, một số outlier ở giá trị cao xuất phát từ hành vi mua sắm bất thường.

5.4 FP-Growth Association Rule Results

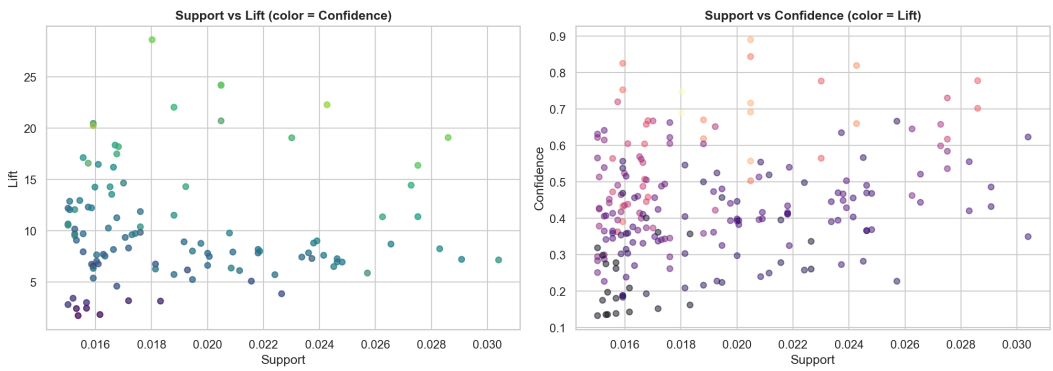

Hình 13: Phân tích luật kết hợp: Support vs Lift (trái) và Support vs Confidence (phải).

Phân tích:

– Các luật có Lift cao (> 5) cho thấy mối quan hệ mạnh giữa các sản phẩm.

– Đa số luật có Support thấp nhưng Confidence cao — phù hợp cho recommendation systems.

5.5 Business Analysis

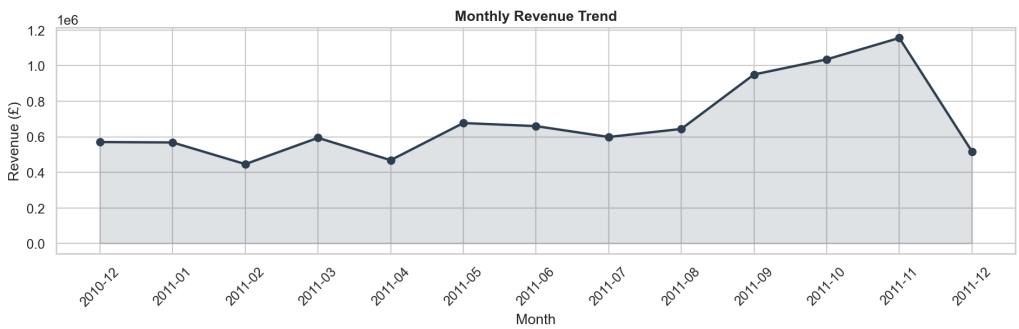

Hình 14: Xu hướng doanh thu theo tháng — cho thấy tính mùa vụ rõ rệt.

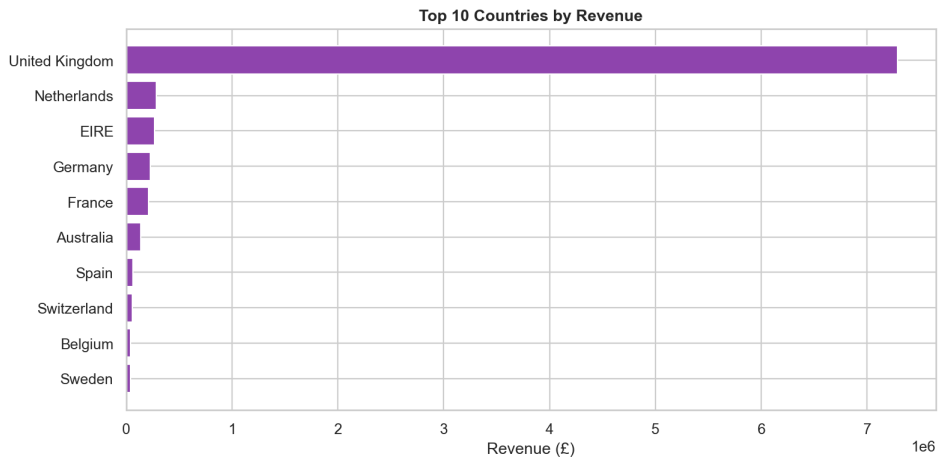

Hình 15: Top 10 quốc gia theo doanh thu.

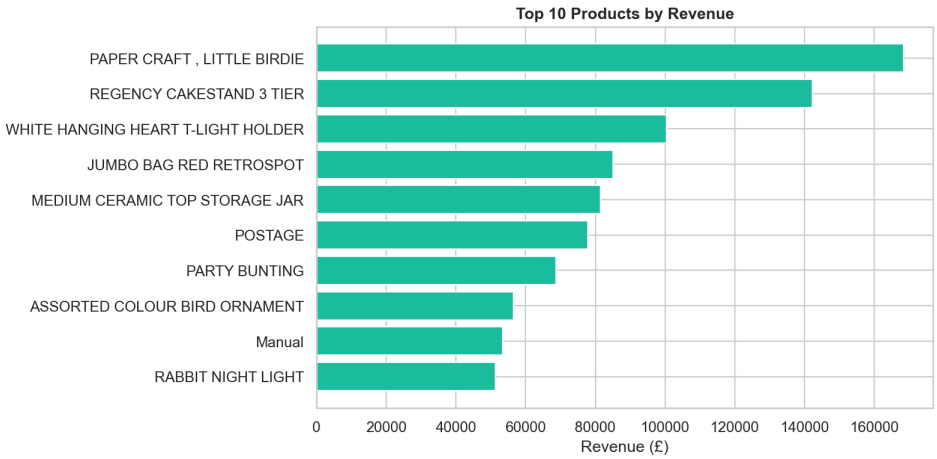

Hình 16: Top 10 sản phẩm theo doanh thu.

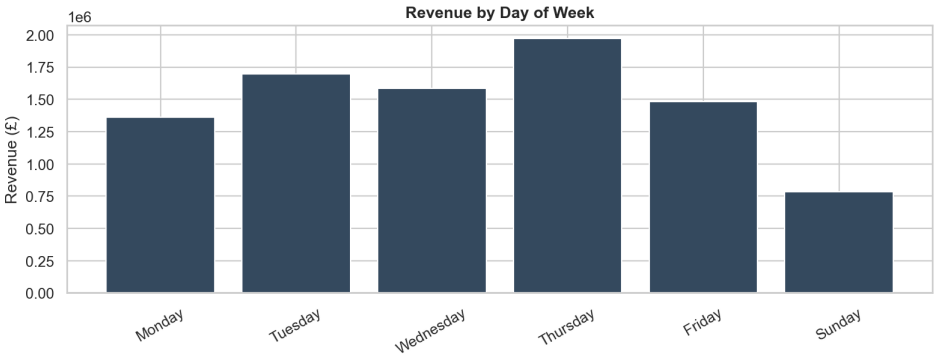

Hình 17: Phân bố doanh thu theo ngày trong tuần.

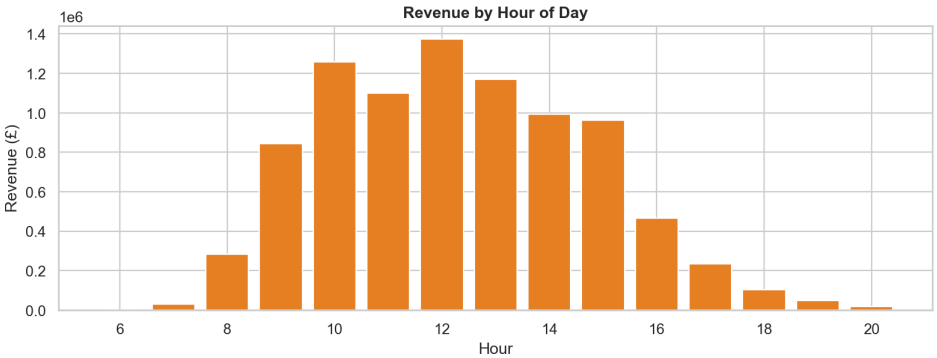

Hình 18: Phân bố doanh thu theo giờ trong ngày.

6 Knowledge Presentation / Application

6.1 Interactive Dashboard

Ứng dụng `streamlit_app.py` cung cấp 3 tab chức năng:

1. **Dashboard:** Hiển thị KPI tổng quan (Total Revenue, Total Customers, Average Spend, Average Frequency) cùng với 6+ biểu đồ tương tác Plotly (Monthly Revenue, Top Countries, Top Products, RFM Distribution, Cluster Pie Chart, Cluster Scatter).
2. **AI Customer Intelligence:** Nhập CustomerID để xem phân cụm KMeans, dự đoán CLV (XGBoost), và tối đa 5 sản phẩm gợi ý bán chéo (FP-Growth).
3. **Pipeline Log:** Xem nhật ký chi tiết của pipeline ETL + Model Training.

6.2 Decision Support Applications

Kết quả phát hiện từ dữ liệu hỗ trợ ra quyết định ở 3 cấp độ:

Bảng 5: Ứng dụng kết quả khai phá dữ liệu vào quyết định kinh doanh

Mô hình	**Tri thức phát hiện**	**Hành động kinh doanh**
KMeans Clustering	4 phân khúc khách hàng	Chiến lược marketing phân biệt: khuyến mãi cho "At Risk", loyalty program cho "Champions"
XGBoost CLV	Dự đoán chi tiêu tương lai	Phân bổ ngân sách marketing: đầu tư nhiều hơn vào khách hàng có CLV cao
FP-Growth Rules	Mẫu mua hàng đồng thời	Gợi ý bán chéo (cross-sell) trên website, email marketing, bundling sản phẩm

7 Pipeline Logging and Reproducibility

Pipeline ghi chi tiết mọi bước vào file `report/generated/pipeline.log`, bao gồm:

- Thời gian thực thi của từng phase (Extract, Transform, Load, Train, Visualize).

- Số lượng bản ghi tại mỗi bước làm sạch.
- Thống kê mô tả dữ liệu.
- Kết quả huấn luyện mô hình (Silhouette, RMSE, R^2, feature importance).
- Cluster profile (RFM trung bình mỗi cụm).
- Top 5 association rules.

Toàn bộ kết quả được lưu vào `report/generated/summary.json` dưới dạng JSON có thể tái sử dụng.

7.1 Generated Artifacts

Pipeline tạo ra các file sau:

- **Mô hình:** `output/models/kmeans.pkl`, `xgb_model.pkl`, `rules.pkl`, `scaler.pkl`
- **Báo cáo:** `report/generated/summary.json`, `metrics.tex`, `pipeline.log`
- **Hình ảnh:** 17 file PNG trong `report/generated/figures/`
- **Database:** PostgreSQL (hoặc SQLite fallback `retail_dw_fallback.db`)

8 Conclusion and Future Work

8.1 Main Findings and Contributions

1. Xây dựng thành công pipeline ETL tự động end-to-end với khả năng fallback (PostgreSQL → SQLite).
2. Star Schema cho Data Warehouse bán lẻ với 4 bảng chiều và 1 bảng sự kiện.
3. KMeans phân cụm 4 phân khúc khách hàng có ý nghĩa kinh doanh rõ ràng.
4. XGBoost dự đoán CLV với kết quả R^2 cho thấy mô hình có khả năng giải thích.
5. FP-Growth sinh luật kết hợp có giá trị cho bán chéo sản phẩm.
6. Dashboard tương tác kết hợp BI và AI serving.

8.2 Limitations

- **Dữ liệu:** Chỉ 1 năm dữ liệu, thiếu thông tin nhân khẩu học khách hàng.
- **Mô hình K-Means:** Giả định cụm hình cầu, có thể không phù hợp nếu phân bố phức tạp. Chưa thử nghiệm DBSCAN hay Gaussian Mixture.
- **XGBoost:** Chưa tối ưu hyperparameter (Grid Search, Bayesian Optimization).
- **FP-Growth:** Chỉ áp dụng cho thị trường UK, chưa mở rộng ra toàn bộ quốc gia.
- **Dashboard:** Chưa có authentication, chưa deploy lên cloud.

8.3 Future Work

1. Tích hợp thêm nguồn dữ liệu (website analytics, customer reviews) vào DW.
2. Thử nghiệm Deep Learning (LSTM, Transformer) cho time-series CLV prediction.
3. Deploy pipeline lên cloud (AWS, GCP) với Apache Airflow scheduler.
4. Áp dụng DBSCAN hoặc Hierarchical Clustering cho phân cụm linh hoạt hơn.
5. Xây dựng A/B testing framework cho đánh giá hiệu quả recommendation.
6. Thêm real-time streaming với Apache Kafka cho cập nhật dữ liệu liên tục.
7. Sử dụng Power BI hoặc Tableau cho enterprise-grade visualization.

9 References