Xây dựng hệ thống Data Warehouse và Phân tích Dữ liệu Bán lẻ Trực tuyến

Kho Dữ Liệu và Hệ hỗ trợ quyết định — HCMUT

Phạm Quang Hiếu – 2310974 **Nguyễn Trung Hiếu – 2310965**

Tháng 04/2026

GVHD: Bùi Tiến Đức

Nội dung trình bày

Giới thiệu đề tài

Data Preprocessing

Kiến trúc hệ thống

K-Means Clustering

XGBoost — Dự đoán CLV

FP-Growth — Luật kết hợp

Kết quả thực nghiệm

Ứng dụng & Dashboard

Kết luận

Giới thiệu đề tài

1. Bối cảnh và Động lực

Vấn đề: Doanh nghiệp bán lẻ trực tuyến tạo ra lượng dữ liệu giao dịch khổng lồ nhưng thiếu công cụ khai thác.

Vì sao OLTP không đủ?

- **OLTP** tối ưu cho ghi/đọc từng giao dịch.
- **VD:** Truy vấn "Tổng doanh thu Q4 theo quốc gia" trên OLTP cần quét toàn bộ bảng $\Rightarrow$ chậm.
- **OLAP** (DW) tổ chức theo chiều phân tích $\Rightarrow$ nhanh hơn hàng chục lần.

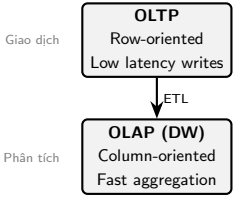

Giải pháp: Data Warehouse + BI + Data Mining theo mô hình Kimball.

2. Mục tiêu nghiên cứu

Câu hỏi: Xây dựng hệ thống DW hoàn chỉnh cho bán lẻ, phân tích hành vi và dự đoán giá trị khách hàng?

6 mục tiêu cụ thể:

1. Pipeline **ETL** tự động
2. Thiết kế **Star Schema**
3. Phân cụm KH (**K-Means + RFM**)
4. Dự đoán CLV (**XGBoost**)
5. Luật kết hợp SP (**FP-Growth**)
6. Dashboard (**Streamlit + Plotly**)

Ý nghĩa thực tiễn:

- **Quản trị KH:** Xác định nhóm KH giá trị cao, KH nguy cơ rời bỏ.
- **Dự báo:** CLV giúp lập ngân sách marketing.
- **Tối ưu:** Cross-selling tăng giá trị đơn hàng.

3. Tập dữ liệu — Online Retail Dataset

Nguồn: Kaggle — Giao dịch thực tế từ công ty bán lẻ quà tặng tại UK.

Thuộc tính	Giá trị
Bản ghi (raw)	541,909
Số thuộc tính	8
Kích thước	∼46 MB
Giai đoạn	12/2010 – 12/2011
Định dạng	CSV (ISO-8859-1)

Cột	Kiểu	Mô tả
InvoiceNo	String	Mã hóa đơn (C=hủy)
StockCode	String	Mã sản phẩm
Description	String	Tên sản phẩm
Quantity	Integer	Số lượng mua
InvoiceDate	DateTime	Thời gian giao dịch
UnitPrice	Float	Đơn giá (£)
CustomerID	Float	Mã khách hàng
Country	String	Quốc gia

Data Preprocessing

4. Quy trình làm sạch dữ liệu

5 bước tuần tự: Mỗi bước loại bỏ một loại dữ liệu không hợp lệ.

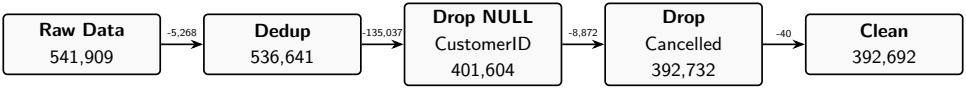

- **Missing CustomerID** (∼25%): Loại bỏ — khóa chính cho phân tích RFM.
- **Duplicates:** 5,268 bản ghi trùng lặp.
- **Hóa đơn hủy** (InvoiceNo bắt đầu "C"): Không phản ánh hành vi mua thực tế.
- **Quantity/UnitPrice** $\leq$ **0**: Không hợp lệ.

5. Feature Engineering — Phân tích RFM

RFM: Phương pháp phân khúc KH kinh điển trong marketing

- **Recency (R):** Số ngày từ lần mua cuối.
  VD: KH mua 5 ngày trước $\Rightarrow R = 5$.
- **Frequency (F):** Số hóa đơn duy nhất.
  VD: KH có 10 hóa đơn $\Rightarrow F = 10$.
- **Monetary (M):** Tổng chi tiêu.
  VD: KH chi £2,500 $\Rightarrow M = 2500$.

Biến tạo thêm:

- TotalPrice = Quantity $\times$ UnitPrice
- InvoiceDate $\rightarrow$ Year, Month, Quarter

Chuẩn hóa (StandardScaler):

$$z = \frac{x - \mu}{\sigma}$$

Lý do: RFM phân bố rất lệch (skewed) $\Rightarrow$ z-score giúp K-Means không thiên vị bởi scale.

Encoding (FP-Growth):
Basket matrix one-hot:
1 = đã mua, 0 = không mua.

Kiến trúc hệ thống

6. Kiến trúc tổng thể

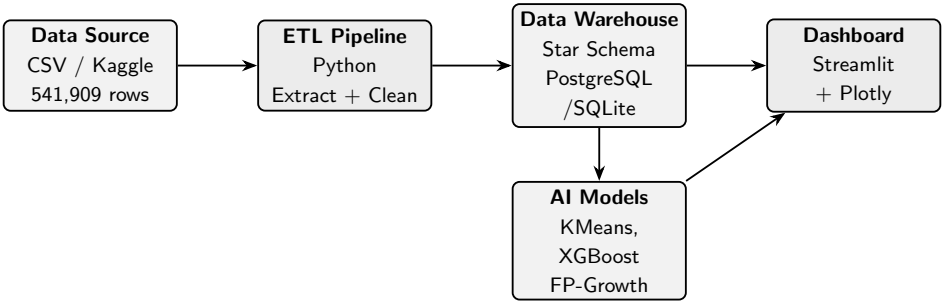

Đặc điểm:

- **End-to-end:** CSV → ETL → DW → AI → Dashboard.
- **Fallback:** PostgreSQL (Docker) → SQLite.
- **Auto-generated:** 17 figures, metrics, summary, 4 model .pkl.

7. Thiết kế Star Schema

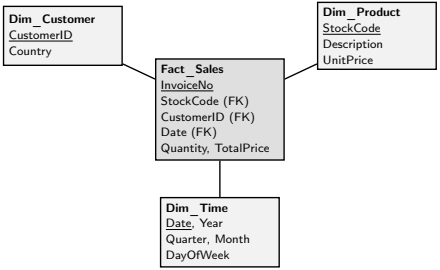

Star Schema: 1 bảng fact trung tâm kết nối các bảng dimension.

VD: *"Doanh thu Q4 theo quốc gia"*
$\Rightarrow$ JOIN Fact $\bowtie$ Dim_Time $\bowtie$ Dim_Customer.

Bảng phân tích bổ sung:

- `Customer_RFM`: R, F, M mỗi KH
- `Customer_Cluster`: RFM + cluster label phục vụ dashboard

Sau ETL: 4,338 KH · 3,665 SP · 18,532 HĐ · 37 QG

K-Means Clustering

8. K-Means: Lý thuyết

K-Means: Phân cụm không giám sát, tối thiểu hóa:

$$J = \sum_{i=1}^{k} \sum_{x \in C_i} \|x - \mu_i\|^2$$

Quy trình:

1. Khởi tạo k tâm cụm $\mu_1, \ldots, \mu_k$.
2. **Gán:** Mỗi $x \to$ cụm có μ_i gần nhất.
3. **Cập nhật:** $\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$.
4. Lặp 2–3 cho đến hội tụ.

VD: 3 KH có RFM = (5,10,2000), (200,1,50), (3,15,5000)
$\Rightarrow$ KH 1&3 gần nhau ("Active"), KH 2 riêng ("At Risk").

Chọn k tối ưu:

- **Elbow:** Vẽ Inertia theo k, chọn "khuỷu tay".
- **Silhouette:** Đo tách biệt giữa các cụm.

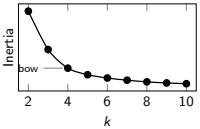

$k = 4$ *(elbow + domain knowledge).*

9. K-Means: Cấu hình & Kết quả

Tham số:

- Input: RFM chuẩn hóa (4,338 KH)
- `n_clusters=4, random_state=42`
- `n_init=10`

Metrics:

Metric	Giá trị
Silhouette	**0.6162**
Calinski-Harabasz	3,145.06
Davies-Bouldin	0.7542

Silhouette > 0.6*: phân cụm tốt.*
Davies-Bouldin < 1*: cụm chặt.*

Profiling 4 cụm (RFM trung bình):

	C0	C1	C2	C3
#KH	3,054	1,067	13	204
R (ngày)	44	248	7	16
F (lần)	3.7	1.6	82.5	22.3
M (£)	1,354	479	127K	12,691

Diễn giải:

- **C0 – Low Value:** Đông nhất và chi tiêu thấp.
- **C1 – At Risk:** Đã inactive lâu ngày, chi tiêu thấp.
- **C2 – Champions:** Tần suất cao và chi tiêu cực cao, thường xuyên (13 KH).
- **C3 – Loyal:** Mua gần đây, thường xuyên, chi nhiều.

XGBoost — Dự đoán CLV

10. XGBoost Regression: Lý thuyết

XGBoost: Kết hợp nhiều cây quyết định yếu thành mô hình mạnh (gradient boosting).

Hàm mục tiêu:

$$\mathcal{L} = \underbrace{\sum_i l(y_i, \hat{y}_i)}_{\text{Loss}} + \underbrace{\sum_k \Omega(f_k)}_{\text{Regularization}}$$

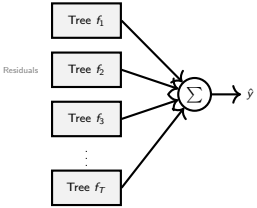

Ý tưởng:

1. Cây 1 dự đoán $\hat{y}^{(1)}$.
2. Cây 2 học *sai số* $y - \hat{y}^{(1)}$.
3. Cây t: $\hat{y}^{(t)} = \sum_{k=1}^{t} f_k(x)$.

VD: Cây 1 dự đoán £1000, thực tế £1500 ⇒ cây 2 học chênh lệch £500.

Regularization $\Omega(f_k)$: Penalize cây quá phức tạp ⇒ chống overfitting.

11. XGBoost CLV: Cấu hình & Kết quả

Bài toán: Dự đoán *FutureSpend* (tổng chi tiêu 3 tháng cuối) từ RFM.

Tham số:

- Train/Test: 80/20
- `n_estimators=100`
- `learning_rate=0.1`
- `max_depth=5`

Feature Importance:

Feature	Importance
Monetary	**0.4546**
Recency	0.3497
Frequency	0.1957

Metrics:

Metric	Giá trị
RMSE	4,753.40
MAE	764.49
Median AE	240.13
R^2	0.3832
Explained Var.	0.3833
sMAPE	124.89%

Phân tích:

- R^2=0.38: Giải thích 38% biến thiên.
- MedAE (240) $\ll$ MAE (764): có outlier.
- **Monetary** mạnh nhất — "chi nhiều $\Rightarrow$ tiếp tục chi nhiều".

FP-Growth — Luật kết hợp

12. FP-Growth: Lý thuyết

FP-Growth: Khai phá tập phổ biến bằng FP-Tree nén — **không sinh ứng viên** như Apriori.

3 metrics:

- **Support:** $P(A \cup B)$
  VD: 150/10K GD chứa Mug & Plate $\Rightarrow$ 0.015.
- **Confidence:** $P(B|A) = \frac{P(A \cup B)}{P(A)}$
  VD: 150/300 $\Rightarrow$ Conf = 0.5.
- **Lift:** $\frac{P(B|A)}{P(B)}$, Lift > 1 = tương quan dương.
  VD: Lift=10 $\Rightarrow$ mua Mug tăng XS mua Plate gấp 10×.

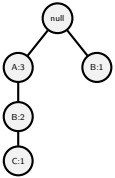

FP-Tree nén giao dịch

Ưu điểm FP-Growth:

- Quét DB **2 lần** (vs Apriori: k lần)
- Không sinh candidate set
- Nhanh hơn với dữ liệu lớn

13. FP-Growth: Cấu hình & Kết quả

Tham số:

- Basket matrix: giao dịch UK, one-hot
- `min_support = 0.015` (1.5%)
- Luật: `lift` $\geq$ `1.5`

Kết quả:

Metric	Giá trị
Frequent itemsets	**440**
Rules generated	**214**
Avg support	0.0191
Avg confidence	0.4375
Avg lift	10.199
Max lift	28.628

Phân tích:

- 214 luật: đủ cho recommendation.
- Avg lift = 10.2: tương quan mạnh.
- Max lift = 28.6: cặp SP cực mạnh.
- Pattern: *support thấp, lift cao* $\Rightarrow$ phù hợp gợi ý cá nhân hóa.

VD luật:
Mua 'ALARM CLOCK RED' $\Rightarrow$ *xác suất cao mua 'ALARM CLOCK GREEN'*
$\Rightarrow$ Gợi ý bundle cùng dòng sản phẩm.

Kiểm thử mô hình và recommendation

- **KMeans:** 3 probe profiles mới được dùng để kiểm tra khả năng gán cụm của mô hình.
- **XGBoost:** 5 mẫu holdout được ghi lại với actual/predicted để kiểm tra trên dữ liệu chưa thấy.
- **FP-Growth:** Top rules và một ví dụ khách hàng cụ thể được dùng để minh họa recommendation bán chéo.
- Toàn bộ bảng chi tiết được sinh tự động trong `generated/metrics.tex`.

Kết quả thực nghiệm

14. Tổng hợp Pipeline Data Profile

Thống kê dữ liệu:

Metric	Value
Raw rows	541,909
After dedup	536,641
Clean rows	392,692
Customers	4,338
Products	3,665
Invoices	18,532
Countries	37
Revenue	£8,887,209

Đánh giá định lượng:

Mô hình	Metric chính	Đánh giá
KMeans	Silhouette = 0.62 DB = 0.75	**Đạt**
XGBoost	R^2 = 0.38 MAE = 764	**Đạt** **một phần**
FP-Growth	214 rules Avg lift = 10.2	**Đạt**

Pipeline sinh: 17 figures, summary.json, metrics.tex, 4 model .pkl.

Trực quan: K-Means Clustering

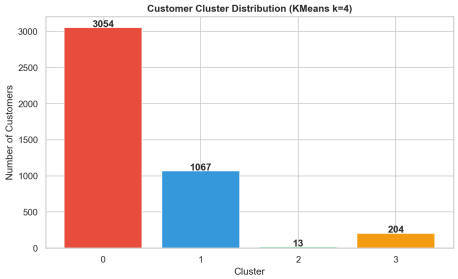

Figure 1: *

Phân bố KH theo cụm ($k = 4$)

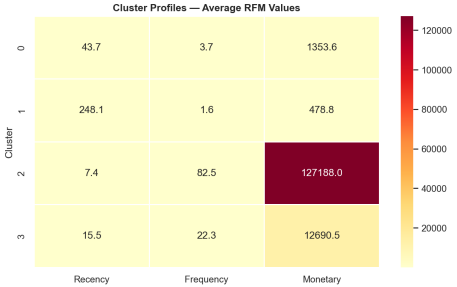

Figure 2: *

Heatmap RFM trung bình mỗi cụm

Nhận xét: C0 (Loyal) chiếm đa số (3,054 KH). C2 (Champions) chỉ 13 KH nhưng M = £127K.

Trực quan: Elbow + Silhouette & 3D Scatter

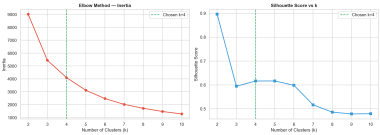

Figure 3: *

Elbow Method & Silhouette Score

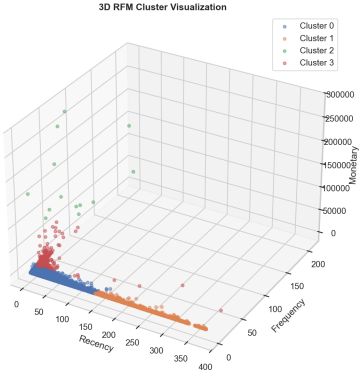

Figure 4: *

3D scatter: cụm KH trong không gian RFM

Nhận xét: Elbow rõ tại $k = 4$. Silhouette cao nhất tại $k = 2$ nhưng $k = 4$ chi tiết hơn.

Trực quan: XGBoost CLV Prediction

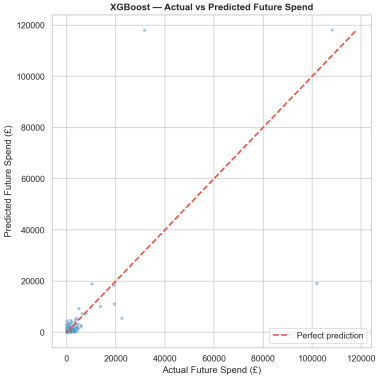

Figure 5: *

Actual vs Predicted

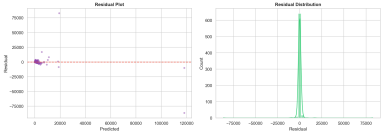

Figure 6: *

Residual analysis

Nhận xét: Điểm gần $y = x \Rightarrow$ dự đoán hợp lý. Residual lệch phải $\Rightarrow$ underestimate outlier.

Trực quan: Feature Importance & FP-Growth

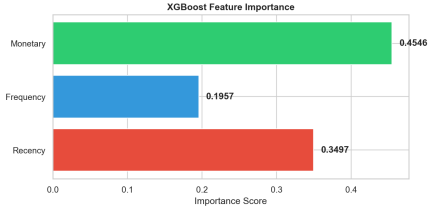

Figure 7: *

Feature Importance (XGBoost)

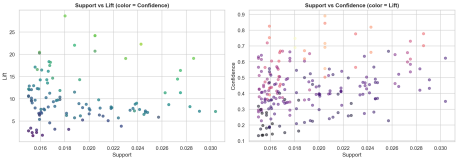

Figure 8: *

Support vs Lift & Confidence

Nhận xét: Monetary = 45.5% importance. FP-Growth: lift cao (>10) + support thấp — gợi ý cá nhân hóa.

Trực quan: Holdout Test & Probe Predictions

XGBoost Holdout Test Examples (5 Test Instances)

Recency	Frequency	Monetary	Actual	Predicted	Error
15.00	3.00	855.00	1763.23	553.38	-1209.85
24.00	3.00	539.13	213.64	313.28	99.64
15.00	5.00	797.02	219.12	553.38	334.26
91.00	2.00	1399.11	591.90	629.75	37.85
233.00	1.00	63.00	0.00	38.84	38.84

KMeans Probe Predictions on New Customer Profiles

Profile	Recency	Frequency	Monetary	Cluster
at_risk	263.00	1.00	155.30	1
loyal	51.00	9.00	668.57	0
champion	5.00	9.00	3640.84	0

Nhận xét: XGBoost: 4/5 dự đoán hợp lý, lỗi lớn nhất do outlier. KMeans: cả 3 probe được gán tương đối đúng cụm (at_risk=1, loyal/champion=0).

Trực quan: FP-Growth Top Rules & Customer Recommendation

Top 5 Association Rules by Lift

Antecedents	Consequents	Supp.	Conf.	Lift
WOODEN HEART XMAS	WOODEN STAR XMAS	0.0180	0.6897	28.63
WOODEN STAR XMAS	WOODEN HEART XMAS	0.0180	0.7481	28.63
GREEN REGENCY TEA	PINK&ROSES REGENCY TEA	0.0205	0.5572	24.22
PINK&ROSES REGENCY TEA	GREEN REGENCY TEA	0.0205	0.8903	24.22
PINK REGENCY TEA	GREEN&ROSES REGENCY TEA	0.0205	0.6917	24.19

Nhận xét: Những mặt hàng cùng loại (cùng dòng sản phẩm) có lift rất cao (>24) $\Rightarrow$ cơ hội cross-sell mạnh.

Trực quan: FP-Growth Top Rules & Customer Recommendation

Customer Recommendation Example

Field	Value
CustomerID	12886
Purchased Items	12 PENCILS TUBE WOODLAND, 3 HOOK PHOTO SHELF, BISCUIT CUTTERS SET, [...+7 more]
Matched Rules	PINK & ROSES REGENCY TEA
Recommended	**GREEN REGENCY TEA**
Support	0.0205
Confidence	0.8903
Lift	24.2167

Nhận xét: KH 12886 đã mua PINK + ROSES $\Rightarrow$ gợi ý GREEN với confidence=89%.

Trực quan: Business Insights

Figure 9: *

Doanh thu theo tháng

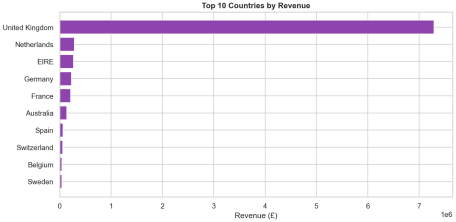

Figure 10: *

Top 10 quốc gia theo doanh thu

Insights:

- Doanh thu tăng mạnh Q4 (mùa lễ) $\Rightarrow$ tăng inventory trước Q4.
- UK chiếm ưu thế $\Rightarrow$ cơ hội mở rộng sang EU.

Ứng dụng & Dashboard

15. Ứng dụng — Decision Support

Dashboard (Streamlit + Plotly): 3 tab:

1. **Dashboard:** KPI + 6+ biểu đồ tương tác.
2. **AI Customer Intelligence:** Nhập CustomerID → phân cụm, CLV, cross-sell.
3. **Pipeline Log:** Nhật ký ETL + training.

Mô hình	Hành động KD
KMeans	Khuyến mãi cho At Risk, loyalty cho Champions
XGBoost	Đầu tư budget vào KH CLV cao
FP-Growth	Cross-sell & bundling trên web/email

VD: KH 14911 (Champions) $\Rightarrow$ CLV = £15,200 $\Rightarrow$ gợi ý bundle sản phẩm.

Kết luận

16. Đánh giá mục tiêu & Giới hạn

Đánh giá mục tiêu:

- ✓ **ETL:** Tự động, reproducible.
- ✓ **Star Schema:** 3 Dim + 1 Fact + 2 bảng phân tích.
- ✓ **K-Means:** 4 cụm (Sil=0.62).
- ∼ **XGBoost:** R^2=0.38, cần cải thiện.
- ✓ **FP-Growth:** 214 luật, lift cao.
- ✓ **Dashboard:** Tương tác, AI tích hợp.

Giới hạn:

- Dữ liệu chỉ ∼1 năm, thiếu biến bổ sung.
- K-Means: giả định cụm cầu, nhạy outlier.
- XGBoost: chưa tuning hệ thống.
- FP-Growth: chỉ cho thị trường UK.
- Dashboard: chưa authentication, chưa cloud.

17. Hướng phát triển tương lai

Cải thiện mô hình:

1. Tích hợp clickstream, CRM data.
2. Hyperparameter tuning (Bayesian).
3. Thử LSTM/Transformer cho CLV.
4. So sánh DBSCAN, GMM, Hierarchical.

Cải thiện hệ thống:

5. Hybrid recommender + A/B testing.
6. Cloud deploy, Airflow, CI/CD.
7. Auth, role-based access, drill-down.

Thank You!

Q & A